


Mémoire

Les CNNs et leur biais en paléontologie, étude de cas sur des céphalopodes du Trias


Titouan COLIN

2025



Encadré par : Arnaud BRAYARD

Référent de Master : Christophe THOMAZO



**UNIVERSITÉ
BOURGOGNE
EUROPE**



A- TABLE DES MATIERES

A-	Table des matières	2
B-	Table des figures.....	3
C-	Tableaux	5
D-	Résumé (Français).....	6
E-	Abstract (english)	6
F-	Brève introduction :.....	7
G-	Travaux associés :.....	7
G-1	Réseaux neuronaux convolutifs	7
G-2	En paléontologie.....	7
H-	Méthodes :.....	8
H-1	Bases de données :.....	8
H-1.1	Publications utilisées :.....	8
H-1.2	Données en libre accès :.....	9
H-1.3	Test des biais :	10
H-2	Modèles CNN :.....	12
H-2.1	Architectures et Hyperparamètres :.....	12
H-2.2	Augmentation :.....	16
H-2.3	Architectures retenues	17
H-2.4	Les autres architectures ML :.....	17
H-3	Interprétation :.....	17
H-3.1	Courbe d'apprentissage	17
H-3.2	Grad-CAM, Guided Grad-CAM	18
H-3.3	LIME	18
H-3.4	t-SNE	18
H-3.5	Matrice de confusion.....	18
H-3.6	ROC-AUC	18
I-	Résultats :.....	19
I-1	Les bases de données fiabilités.....	19
I-2	Les bases de données vues	20
I-3	La base de données fragments.....	21
I-4	Les bases de données mixtes	21
J-	Discussion :.....	22
J-1	Biais de collecte	22

J-1.1	Biais spatial et chronologique	22
J-1.2	Biais d'intérêt	23
J-2	Identification fine et variation intra-spécifique	24
J-3	Biais de la méthode	27
J-3.1	Biais de cadrage	27
J-3.2	Biais d'identification	28
J-3.3	Biais de représentation	29
J-3.4	Déséquilibre et quantité des données	31
J-4	Une solution parcimonieuse	32
J-4.1	Application réel	32
J-4.2	Limitation	32
J-4.3	Piste d'amélioration.....	33
K-	Conclusion.....	33
L-	Disponibilité des données.....	33
M-	Remerciement.....	34
N-	Bibliographie	34

B- TABLE DES FIGURES

Fig. 1: Modifié d'après Chollet (2021) : (A gauche) Schéma de l'architecture VGG16 élaborer pour la compétition ImageNet. (A droite) Schéma d'une boucle d'entraînement classique d'un CNN. Le schéma de gauche est l'équivalent de la partie 'Layer (data transformation)' du schéma de droite.....	7
Fig. 2: Exemple de céphalopodes recadrées et redimensionnées pour l'entraînement.	8
Fig. 3: Schéma de la répartition des ensembles ' Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence des modèles publications.	9
Fig. 4: Schéma des taux de préservations des spécimens retenus pour l'ensemble test.	11
Fig. 5:Schéma de la répartition des ensembles ' Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence du modèle vues. Le modèle de vue mixte sera comparé à l'ensemble 'Test' des vues transversales et des vues latérales.	11
Fig. 6: Schéma de la répartition des ensembles ' Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence du modèle. L'ensemble 'Test' est composé uniquement de fragments d'individus.....	11
Fig. 7:Schéma de la répartition des ensembles ' Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence du modèle cadrage. L'ensemble 'Test' regroupe les données des trois ensembles de fiabilités.	12
Fig. 8: Schéma du fonctionnement d'un conteneur Nvidia modifié d'après https://www.adaltas.com/fr/2022/03/24/nvidia-docker/ . Bien que plus gourmand en puissance de calcul, cette mise en place est compatible sur toutes les distributions populaires ainsi que sur les derniers drivers Nvidia.....	12

Fig. 9: Exemple d'un spécimen du genre <i>Sagenites</i> (Mojsisovics, 1879) redimensionné à 512x512, 380x380 et 256x256 pixels.	13
Fig. 10: Modifié d'après Srivastava et al. (2014). Exemple du 'dropout' appliqué à un réseau neuronal.	14
Fig. 11: Modifié d'après Tan et Le (2019). Exemple d'un bloque résiduel (à gauche) et de sa contrepartie excitation/compression (à droite).	14
Fig. 12: Modifié d'après Chollet (2021), exemple de l'effet du taux d'apprentissage sur un espace en 2 dimensions.	14
Fig. 13: Modifié d'après Hinton et al. (2012). Exemple d'un effet « canyon » dans un espace en deux dimensions. Un taux d'apprentissage trop élevé empêche une convergence rapide. Un effet « crête » est aussi possible.	15
Fig. 14: Modifié d'après Abushawish et al. (2024). Schéma d'un transfert d'apprentissage d'une architecture construit pour ImageNet vers une architecture avec un objectif différent (ici sur des céphalopodes).	15
Fig. 15: Modifié d'après Haden (https://medium.com/data-science/how-to-cross-validation-with-time-series-data-9802a06272c6). Schéma d'une validation croisée à 5 plis.	16
Fig. 16: Exemples d'itérations d'une même photo après augmentations.	16
Fig. 17: Courbe d'entraînement des modèles InceptionResNetV2 380x380 très fiable (à gauche), fiable (au milieu), peu fiable (à droite). Remarquez le découplage entre la précision de l'entraînement et de la validation après le transfert d'apprentissage. C'est un symptôme typique de surapprentissage. L'impact est visible sur les courbes des pertes avec des variations plus intenses à partir des 110 époques.	19
Fig. 18: Courbe d'entraînement d'un des plis des modèles EfficientNetB4 380x380 très fiable (à gauche), fiable (au milieu), peu fiable (à droite). Les valeurs sont plus variables que celles non normées, montrant bien la nécessité d'une validation croisée.	20
Fig. 19: Courbes d'entraînements du modèle fragments.	21
Fig. 20: Modifié d'après Gbif (https://www.gbif.org/fr/), répartition des céphalopodes fossiles sur le globe. Leur concentration est principalement située en Europe et en Amérique du Nord.	22
Fig. 21: Exemple de spécimens fragmentés avec leur prédiction et leur vraie identification. .	23
Fig. 22: (À gauche) matrice de confusion et (à droite) courbe ROC avec scores AUC du modèle fragments.	23
Fig. 23: Guided-Grad-CAM et Grad CAM de trois spécimens <i>Dieneroceras</i> (Spath, 1934), <i>Trachyceras</i> (Laube, 1869) et <i>Meekoceras</i> (Hyatt, 1879). Notez la mauvaise prédiction de <i>Meekoceras</i> (Hyatt, 1879) en <i>Hemiprionites</i> (Spath, 1929), sur un spécimen très fragmenté et peu ornementé.	24
Fig. 24: Graphique t-SNE des modèles mixtes+gbif espèces (en haut) et mixtes (en bas). Les données à observer sont les espèces appartenant à un même genre. Par exemple, une concentration des points de <i>A.kingianius</i> (Waagen, 1895) et <i>A.multiformis</i> (Welter, 1922) forme un ensemble indissociable (cercle en pointillé) démontrant la difficulté des modèles à les différencier. Ici, les scores et les données étant assez limités, il est difficile d'en tirer des conclusions plus poussées.	25
Fig. 25: Matrices de confusion des modèles mixtes+gbif_sp (en haut) et mixtes_sp (en bas). Les espèces d'un même genre sont encadrées en bleu. Notez la confusion de <i>P.compressa</i> (Hyatt & Smith, 1905) en <i>A.acutus</i> (Hyatt & Smith, 1905). Les quantités de données de <i>P.compressa</i> (Hyatt & Smith, 1905) sont faibles (100 photos). L'ensemble 'test' (5% soit 5 photos)	

aléatoirement réparti ne présente ‘malheureusement’ que des vues transversales confondues avec celle de <i>A. acutus</i> (Hyatt & Smith, 1905) (aux caractères déterminants très proches).	26
Fig. 26: Guided Grad-CAM et Grad-CAM montrant l'attention du modèle dispersée sur l'arrière-plan et les annotations.....	27
Fig. 27: LIME montrant une attention positive (vert) et négative (rouge) sur l'arrière-plan des photos. Les deux photos à gauche sont les prédictions les plus probables. Les deux photos à droite sont les moins probables.	27
Fig. 28: Matrice de confusion, Courbe ROC-AUC et graphique t-SNE pour les modèles très fiable normés (à gauche), fiable normés (milieu) et peu fiable normés (à droite)). Remarquez <i>Anasibirites</i> (Waagen, 1895) généralement bien différencié dans les graphiques t-SNE	28
Fig. 29: Guided Grad CAM, Grad CAM et LIME pour les vues latérales (gauche) et transversales (droite). La vue latérale Guided Grad-CAM de <i>Meekoceras</i> (Hyatt, 1879) porte une attention sur les sutures visibles. LIME montre que cette attention est détrimentaire à la prédiction.....	30
Fig. 30: Matrices de confusion et courbes ROC-AUC pour les modèles vus transversal (gauche), latéral (milieu) et mixte (droite).	30
Fig. 31: Graphique comparant le score AUC moyen des modèles EfficientNetV2M avec le nombre de genres par base de données.	31

C- TABLEAUX

Tableau 1: Résumé de la base de données publications	9
Tableau 2: Résumé de la base de données libre accès.....	10
Tableau 3: Résumé de la base de données vues	10
Tableau 4: Résumé de la base de données fragments.....	11
Tableau 5: Résumé de la base de données cadrage	12
Tableau 6: Résultats des modèles de fiabilités publications.....	20
Tableau 7: Résultats des modèles de fiabilités publications normées	20
Tableau 8: Résultats des modèles de vues.....	21
Tableau 9: Résultats du modèle fragments.....	21
Tableau 10: Résultats des modèles mixte et mixte+gbif.....	22

D- RESUME (FRANÇAIS)

Ce mémoire explore l'utilisation des réseaux neuronaux convolutifs (CNNs) pour l'identification taxonomique de céphalopodes fossiles de la limite Permien/Trias et du Trias, en évaluant les biais induits par les données et les méthodes. Face à la rareté croissante d'experts /es en paléontologie et à la complexité des assemblages fossiles, les CNNs apparaissent comme un outil prometteur d'assistance. Dans ce travail, plusieurs bases de données sont construites à partir de publications et de données ouvertes (Gbif), classées selon leur fiabilité, leur qualité photographique et la préservation des spécimens. Les performances des modèles (InceptionResNetV2, EfficientNetV2, MobileNetV3) sont testées à différentes résolutions et configurations, avec transfert d'apprentissage et validation croisée. Malgré des résultats encourageants (identifications correctes : 68,61% pour 95 genres et 77.27% pour 34 espèces), les CNNs montrent des limitations notables en présence de spécimens fragmentés, de vues non standardisées ou de déséquilibres taxonomiques. Ce travail met en lumière plusieurs biais systématiques de cadrage, de collecte, ou encore de représentation et propose des pistes pour renforcer la robustesse des modèles (augmentation, ajout de données). Ce travail représente une continuité de diverses études sur l'intelligence artificielle appliquée en paléontologie et plus particulièrement sur les macrofossiles qui sont encore peu exploités.

E- ABSTRACT (ENGLISH)

This Ms. thesis explores the use of Convolutional Neural Networks (CNNs) for the taxonomic identification of fossil cephalopods from the Triassic and the Permian/Triassic boundary, assessing biases introduced by data and methodologies. Given the shortage of paleontology experts and the complexity of fossil assemblages, CNNs appear to be a promising assistive tool. Several datasets were built from publications and open data (Gbif), classified according to their reliability, photographic perspective, and level of fragmentation. The performance of models (InceptionResNetV2, EfficientNetV2, MobileNetV3) was tested at different resolutions and configurations, using transfer learning and cross-validation. With encouraging results (68.61% for 95 genera and 77.27% for 34 species), CNNs demonstrate notable limitations in the presence of fragmented specimens, non-standardized views, or taxonomic imbalances. The study highlights several systematic biases related to framing, collection, and representation, and suggests ways to improve model robustness (augmentations, additional data). This work continues a growing body of research on artificial intelligence in paleontology, particularly its application to macrofossils, which remains underexplored.

F- BREVE INTRODUCTION :

La paléontologie contribue à de nombreuses disciplines liées aux géosciences, à la biologie et à la chimie (Kitts 1974; Rachootin 1981). Une des étapes indispensables à toute étude paléontologique est la bonne identification taxonomique des spécimens. Par la densité du registre fossile, des spécialistes pouvant fournir ces identifications rigoureuses sont en faible nombre ou n'existent plus aujourd'hui (Currie 2021). Une prise de décision rapide est donc peu aisée pour les néophytes. Ce travail propose de tester les capacités d'identifications basées sur de nouvelles technologies utilisant des Réseaux Neuraux Convolutifs (CNN) en les appliquant aux céphalopodes du Trias et de la limite Permien/Trias. Plusieurs bases de données triées par genres et espèces permettront d'évaluer les biais liés à ces approches. Ces derniers seront interprétés et quantifiés à travers divers algorithmes et méthodes.

G- TRAVAUX ASSOCIES :

G-1 RESEAUX NEURONAUX CONVOLUTIFS

En 2012, Krizhevsky *et al.* (2012) implémentent le premier réseau neuronal convolutif moderne et applicable à des problématiques réelles (e.g. classification et segmentation automatique). Leurs formes ont aujourd'hui évolué pour répondre à d'autres problématiques (e.g. IA génératives, Large Language Model (LLM)).

Les CNNs sont basés sur des neurones arrangés en différentes couches, celle d'entrée, les couches cachées et celle de sortie (Fig. 1). Pour la classification d'images, la couche d'entrée est dimensionnée selon les images, la dernière couche représente le nombre de classes à déterminer. Les couches cachées sont un ensemble de couches convolutives, d'activation non linéaire et de réduction de résolution connectées totalement ou partiellement entre elles (Chollet 2021).

Le modèle est entraîné sur différentes images à travers un nombre d'itérations données. Pour chaque itération, l'algorithme de rétropropagation du gradient (Linnainmaa 1976) met à jour des variables pour augmenter le taux de bonnes prédictions.




Fig. 1: Modifié d'après Chollet (2021) : (A gauche) Schéma de l'architecture VGG16 élaborer pour la compétition ImageNet. (A droite) Schéma d'une boucle d'entraînement classique d'un CNN. Le schéma de gauche est l'équivalent de la partie 'Layer (data transformation)' du schéma de droite.

G-2 EN PALEONTOLOGIE

Plusieurs travaux notables ont été réalisés depuis 2017 sur la classification et la segmentation d'objets paléontologiques. En 2025, elles représentent plus de 38 publications (Ansari *et al.* 2024) portant sur l'identification et la segmentation paléontologique avec une attention portée

principalement sur les microfossiles. Avec une base de données de plus de 34 000 photos de foraminifères modernes, Hsiang *et al.* (2019) démontrent la faisabilité des CNNs à l'identification taxonomique au niveau spécifique ainsi que l'intérêt de cette méthode sur le plan paléoclimatique. A l'instar d'ImageNet (Deng *et al.* 2009), Liu *et al.* (2023) agrègent la Fossil Image Dataset comportant 415 000 photos réparties sur 50 groupes d'organismes fossiles (*e.g.* bivalves, céphalopodes) pour un taux de bonnes prédictions à plus de 90%. Sun *et al.* (2023) classent avec plusieurs limites de données des genres de bivalves et de brachiopodes sur une base de données comprenant plus de 16 000 images.

H- METHODES :

Plusieurs bases de données photographiques sont construites dans le but d'entraîner et de comparer des modèles de prédiction. Les modèles sont basés sur différentes architectures de CNN et interprétés à l'aide de plusieurs méthodes statistiques et exploratoires.

H-1 BASES DE DONNEES :

Les bases de données constituent le fondement d'un modèle performant. Leur qualité dépend de la résolution des photos et de l'information qu'elles portent. La redondance des mêmes photos de spécimens doit être la plus faible possible. Pour chaque base de données, la moyenne de la hauteur et de la largeur en pixels des photos est calculée comme indicateur rapide.

DupeGuru (<https://dupeguru.voltaicideas.net/>), un logiciel libre détectant les doublons, est utilisé sur toutes les bases de données. Le logiciel libre inbac (<https://github.com/weclaw1/inbac>) est utilisé pour recadrer les photos (Fig. 2).




Fig. 2: Exemple de céphalopodes recadrés et redimensionnés pour l'entraînement.

H-1.1 PUBLICATIONS UTILISEES :

Les bases de données sont agrégées à partir d'une collection de publications concentrées sur la période du Trias et la limite Permien-Trias (voir Disponibilité des données). En raison de leur âge et de la qualité variable de leur identification, ces publications sont divisées en trois catégories de fiabilité : « Peu fiable », « Fiable » et « Très fiable ». Cette classification est établie sur l'expertise d'A. Brayard, spécialiste des céphalopodes de cette période.

Pour chaque publication, les spécimens (dessins et photos) sont recadrés de sorte à obtenir une image par représentation de vue de spécimen. Ils sont triés selon leur nomenclature binomiale et collectés de manière exhaustive au niveau du genre et de l'espèce. Les spécimens indéterminés au niveau de la famille et au-delà ne sont pas conservés en raison de leur faible nombre. Ceux indéterminés au niveau du genre sont classés dans une catégorie « indet ».

La taxonomie ayant évolué depuis les publications plus anciennes, les spécimens sont soumis à une vérification systématique des identifications sur la base de données en ligne Gbif (<https://www.gbif.org/fr/>). Cette dernière n'est pas dénuée de biais (Troudet *et al.* 2017; Rocha-Ortega *et al.* 2021) mais elle indique les synonymies révisées plus récemment sur des identifications anciennes. *In fine*, la qualité moyenne des identifications s'en trouve améliorée.




Fig. 3: Schéma de la répartition des ensembles 'Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence des modèles publications.

Pour chaque indice de fiabilité, la base de données est répartie aléatoirement en trois ensembles : « entraînement », « validation » et « test », représentant respectivement 85 %, 10 % et 5 %, sauf contre-indication (Fig. 3). L'ensemble « entraînement » est utilisé pour entraîner le modèle, l'ensemble « validation » permet de régler les hyperparamètres et l'ensemble « test » est uniquement utilisé pour l'interprétation (Tableau 1).

	Très Fiable	nb	Fiable	nb	Peu Fiable	nb
Total	13278		12917		9217	
Top 10 espèces	<i>A.kingianus</i> (Waagen 1895)	317	<i>C.parisianus</i> (Hyatt & Smith, 1905)	203	<i>Juvavites indet</i> (Mojsisovics 1879)	249
	<i>O.koeneni</i> (Hyatt & Smith 1905)	275	<i>M.gracilitatis</i> (White 1879)	138	<i>Tropites indet</i> (Mojsisovics 1875)	240
	<i>A.multiformis</i> (Welter 1922)	238	<i>A.kingianus</i> (Waagen, 1895)	99	<i>Trachyceras indet</i> (Laube 1869)	159
	<i>H.typus</i> (Waagen, 1895)	233	<i>I.originis</i> (Arthaber 1911)	89	<i>Sirenites indet</i> (Mojsisovics 1893)	116
	<i>D.dienneri</i> (Hyatt & Smith, 1905)	149	<i>S.shastense</i> (Silberling 1959)	88	<i>Sagenites indet</i> (Mojsisovics, 1879)	94
	<i>G.smithi</i> (Mathews 1929)	147	<i>O.medium</i> (Griesbach 1880)	84	<i>Halorites indet</i> (Mojsisovics, 1879)	92
	<i>M.chaiburiensis</i> (Tongtherm et al. 2020)	136	<i>P.multilobatum</i> (Noetling 1904)	82	<i>Protrachyceras indet</i> (Mojsisovics, 1893)	91
	<i>J.spathi</i> (Frebold 1930)	133	<i>S.mushbachanum</i> (White, 1879)	79	<i>O.medium</i> (Griesbach, 1880)	81
	<i>P.aspenensis</i> (Hyatt & Smith, 1905)	128	<i>A.multiformis</i> (Welter, 1922)	76	<i>Anatmites indet</i> (Mojsisovics, 1893)	76
	<i>W.perrini</i> (Mathews, 1929)	120	<i>P.aspenensis</i> (Hyatt & Smith, 1905)	74	<i>Tropicelites indet</i> (Mojsisovics, 1893)	67
Top 10 genres	<i>Anasibirites</i> (Waagen, 1895)	617	<i>Tropites</i> (Mojsisovics, 1875)	357	<i>Tropites</i> (Mojsisovics, 1875)	405
	<i>Owenites</i> (Hyatt & Smith, 1905)	465	<i>Anasibirites</i> (Waagen, 1895)	241	<i>Trachyceras</i> (Laube, 1869)	384
	<i>Hemiprionites</i> (Spath & others 1929)	415	<i>Columbites</i> (Hyatt & Smith 1905)	223	<i>Ophiceras</i> (Griesbach, 1880)	331
	<i>Juvenites</i> (Smith 1927)	407	<i>Meekoceras</i> (Hyatt, 1879)	218	<i>Juvavites</i> (Mojsisovics, 1879)	316
	<i>Ambites</i> (Waagen, 1895)	354	<i>Clionites</i> (Hyatt & Smith, 1905)	211	<i>Ceratites</i> (Haan 1825)	278
	<i>Xenocelites</i> (Spath 1930)	307	<i>Tirolites</i> (Mojsisovics, 1879)	169	<i>Nautilus</i> (Linnaeus, 1758)	234
	<i>Dieneroceras</i> (Spath 1934)	279	<i>Discotropites</i> (Hyatt & Smith, 1905)	164	<i>Ammonites</i> (Bruguière 1789)	191
	<i>Tirolites</i> (Mojsisovics, 1879)	244	<i>Juvenites</i> (Smith, 1927)	163	<i>Sirenites</i> (Mojsisovics, 1893)	179
	<i>Gyronites</i> (Waagen, 1892)	220	<i>Nautilus</i> (Linnaeus 1758)	158	<i>Ptychites</i> (Mojsisovics, 1875)	115
	<i>Arctoceras</i> (Hyatt et al. 1900)	217	<i>Ophiceras</i> (Griesbach, 1880)	156	<i>Arcestes</i> (Suess 1865)	111
Nombres différents de genres	382		539		488	
Nombres différents d'espèces	883		1606		1438	
Moyenne Hauteur/Largeur des photos	(1053, 746)		(565, 380)		(374, 258)	

Tableau 1: Résumé de la base de données publications

Une base de données finale mixte, comprenant ces trois bases de données, est également assemblée.

H-1.2 DONNEES EN LIBRE ACCES :

Une base de données annexe, établie sur les données Gbif, est collectée à partir des exports au format Darwin Core (Wieczorek *et al.* 2012), disponibles librement sur le site. Les exports associent l'URL de la photo du spécimen à la nomenclature binomiale de l'espèce, permettant un recoupement avec la base de données publications. À noter que la manière exhaustive dont la base de données publications est construite induit une surreprésentation de certains spécimens récents, comme *N.pompilius* (Linnaeus, 1758), ou d'autres genres ayant une répartition temporelle très large (*e.g.* *Ammonites* (Bruguière, 1789)) (Tableau 2).

D'autres bases de données publiques telles que ReColNat (Pérez & Pignal 2013) ont été considérées, mais leur manque de normalisation dans les formats de classification des exports aurait rendu leur tri trop chronophage dans le cadre de ce mémoire.

Une base de données comprenant les données Gbif et la base de données mixte est également formée. Des variantes avec des limites minimales de 200 et 300 photos par classe, ainsi qu'une variante par espèce, sont agrégées pour les ensembles « mixte » et « mixte+Gbif ».

Les CNNs demandent une quantité importante d'images pour apprendre des caractères déterminants (généralement plus de 1000 par classe d'objets (Deng *et al.* 2009)). La quantité de données paléontologiques recueillies étant assez déséquilibrée selon les genres/espèces, une limite de 100 photos minimum par classe d'objets est définie pour l'entraînement d'un modèle, sauf contre-indication.

	Gbif	nb	Mixte	nb	Mixte+gbif	nb
Total	4594			34329		40291
Top 10 espèces						
	<i>Ammonites indet</i> (Bruguière, 1789)	1281	<i>A.kingianus</i> (Waagen, 1895)	425	<i>Ammonites indet</i> (Bruguière, 1789)	1283
	<i>Orthoceras indet</i> (Bruguière, 1789)	1043	<i>A.multiformis</i> (Welter, 1922)	366	<i>Orthoceras indet</i> (Bruguière, 1789)	1061
	<i>N.pompilius</i> (Linnaeus, 1758)	237	<i>O.koeneni</i> (Hyatt & Smith, 1905)	354	<i>A.kingianus</i> (Waagen, 1895)	429
	<i>C.beyrichi</i> (Welter 1914)	208	<i>Tropites indet</i> (Mojsisovics, 1875)	299	<i>A.multiformis</i> (Welter, 1922)	376
	<i>Clypeoceras indet</i> (Eastman, 1913)	141	<i>H.typus</i> (Waagen, 1895)	277	<i>O.koeneni</i> (Hyatt & Smith, 1905)	355
	<i>Phylloceras indet</i> (Suess, 1865)	140	<i>C.parisianus</i> (Hyatt & Smith, 1905)	265	<i>Tropites indet</i> (Mojsisovics, 1875)	299
	<i>Nautilus indet</i> (Linnaeus, 1758)	107	<i>Juvavites indet</i> (Mojsisovics, 1879)	249	<i>H.typus</i> (Waagen, 1895)	279
	<i>Cenoceras indet</i> (Hyatt 1884)	98	<i>M.gracilitatis</i> (White, 1879)	228	<i>C.parisianus</i> (Hyatt & Smith, 1905)	266
	<i>Billingsites indet</i> (Monnet & Bucher 2005)	64	<i>D.dienieri</i> (Hyatt & Smith, 1905)	227	<i>Juvavites indet</i> (Mojsisovics, 1879)	251
	<i>Flemingites indet</i> (Waagen, 1892)	47	<i>P.aspenensis</i> (Hyatt & Smith, 1905)	202	<i>N.pompilius</i> (Linnaeus, 1758)	244
Top 10 genres						
	<i>Ammonites</i> (Bruguière, 1789)	1281	<i>Anasibirites</i> (Waagen, 1895)	910	<i>Ammonites</i> (Bruguière, 1789)	1480
	<i>Orthoceras</i> (Bruguière, 1789)	1043	<i>Tropites</i> (Mojsisovics, 1875)	767	<i>Orthoceras</i> (Bruguière, 1789)	1108
	<i>Nautilus</i> (Linnaeus, 1758)	385	<i>Owenites</i> (Hyatt & Smith, 1905)	551	<i>Anasibirites</i> (Waagen, 1895)	956
	<i>Cladiscites</i> (Mojsisovics, 1879)	228	<i>Ophiceras</i> (Griesbach, 1880)	550	<i>Tropites</i> (Mojsisovics, 1875)	842
	<i>Clypeoceras</i> (Eastman & Zittel 1913)	144	<i>Juvenites</i> (Mojsisovics, 1879)	544	<i>Nautilus</i> (Linnaeus, 1758)	777
	<i>Phylloceras</i> (Suess, 1865)	140	<i>Meekoceras</i> (Hyatt, 1879)	487	<i>Ophiceras</i> (Griesbach, 1880)	640
	<i>Cenoceras</i> (Hyatt, 1884)	98	<i>Hemiprionites</i> (Spath, 1929)	484	<i>Owenites</i> (Hyatt & Smith, 1905)	590
	<i>Billingsites</i> (Monnet & Bucher, 2005)	76	<i>Trachyceras</i> (Laube, 1869)	451	<i>Juvenites</i> (Mojsisovics, 1879)	582
	<i>Flemingites</i> (Waagen, 1892)	74	<i>Juvavites</i> (Mojsisovics, 1879)	441	<i>Meekoceras</i> (Hyatt, 1879)	513
	<i>Tropites</i> (Mojsisovics, 1875)	73	<i>Xenoceltites</i> (Spath, 1930)	434	<i>Tirolites</i> (Mojsisovics, 1879)	508
Nombres différents de genres	167		846		853	
Nombres différents d'espèces	235		3059		3073	
Moyenne Hauteur/Largeur des photos	(990, 970)		(692, 480)		(735, 544)	

Tableau 2: Résumé de la base de données libre accès


H-1.3 TEST DES BIAIS :

La nature des CNNs reste opaque quant à leur pouvoir décisionnel selon les caractères identifiés. La mise en valeur de possibles biais est effectuée sur plusieurs bases de données annexes.

Les spécimens sont généralement représentés sous deux vues (latérale et transversale) (Arkell *et al.* 1957). Deux bases de données pour chaque vue sont agrégées à partir de la base de données mixte, avec une limite minimale de 400 photos par genre. Une troisième base de données est composée des deux vues avec les mêmes paramètres (Tableau 3)(Fig. 5). La limite minimale plus élevée du nombre de photos restreint les problèmes de quantité dans les ensembles « entraînement », « validation » et « test ».

	Vue latérale	nb	Vue transversale	nb	Vue mixte	nb
Total	3079		2955		6034	
Top 3 genres						
	<i>Anasibirites</i> (Waagen, 1895)	484	<i>Tropites</i> (Mojsisovics, 1875)	434	<i>Anasibirites</i> (Waagen, 1895)	910
	<i>Ophiceras</i> (Griesbach, 1880)	337	<i>Anasibirites</i> (Waagen, 1895)	426	<i>Tropites</i> (Mojsisovics, 1875)	767
	<i>Tropites</i> (Mojsisovics, 1875)	333	<i>Juvenites</i> (Smith, 1927)	316	<i>Owenites</i> (Hyatt & Smith, 1905)	550
Nombres différents de genres		11				
Moyenne Hauteur/Largeur des photos	(744, 678)		(635, 321)		(691, 503)	

Tableau 3: Résumé de la base de données vues



Base de données vues

Fig. 5: Schéma de la répartition des ensembles 'Entrainement', 'Validation' et 'Test' pour l'entraînement et l'inférence du modèle vues. Le modèle de vue mixte sera comparé à l'ensemble 'Test' des vues transversales et des vues latérales.

Le processus de fossilisation et l'échantillonnage peuvent entraîner de la fragmentation et la présence de spécimens incomplets (Schopf 1975). Une base de données est composée des ensembles « entraînement » et « validation » comprenant uniquement des spécimens entiers (plus de 75 % du spécimen). La partie « test » est composée uniquement de fragments (moins de 75 % du spécimen) (Fig. 4) et de spécimens altérés (loge colorée). Cette base de données est construite à partir de la base de données mixte avec une limite minimale de 400 photos par genre (Fig. 6)(Tableau 4).





Fig. 4: Schéma des taux de préservations des spécimens retenus pour l'ensemble test.

	Fragments	nb
Entraînement+validation	5729	
Test	305	
Top 3 genres	Anasibirites (Waagen, 1895)	864
	Tropites (Mojsisovics, 1875)	753
	Owenites (Hyatt & Smith, 1905)	538
Nombres différents de genres	11	
Moyenne Hauteur/Largeur des photos entraînement	(679, 486)	

Tableau 4: Résumé de la base de données fragments



Base de données fragments

Fig. 6: Schéma de la répartition des ensembles 'Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence du modèle. L'ensemble 'Test' est composé uniquement de fragments d'individus.

Les informations transversales non relatives aux spécimens (e.g. couleur de fond, échelle ou annotations similaires entre différents spécimens) sont considérées comme des biais de cadrage (« framing bias ») (Fabbrizzi *et al.* 2022). De même, l'identification variable des spécimens pourrait influencer les prédictions des modèles. Pour évaluer ces biais, trois bases de données

« peu fiable », « fiable » et « très fiable », normalisées à 75 images par genre, sont agrégées (Fig. 7). Les genres sont présents dans les trois bases de données pour la comparaison. L'ensemble « entraînement » et « validation » est réparti en 90 : 10. La partie « test » comprend le reste des photos des trois bases de données regroupées en un seul ensemble. Cette base de données servira également à quantifier l'impact des déséquilibres entre le nombre de photos par genre (Tableau 5).

	Très fiable	Fiable	Peu fiable
Entraînement+validation		300	
Total test		1639	
Genres retenu		<i>Anasibirites</i> (Waagen, 1895) <i>Meekoceras</i> (Hyatt 1879) <i>Ophiceras</i> (Griesbach, 1880) <i>Tirolites</i> (Mojsisovics, 1879)	
Moyenne Hauteur/Largeur des photos d'entraînement	(1187, 824)	(931, 628)	(408, 258)

Tableau 5: Résumé de la base de données cadrage




Fig. 7: Schéma de la répartition des ensembles 'Entraînement', 'Validation' et 'Test' pour l'entraînement et l'inférence du modèle cadrage. L'ensemble 'Test' regroupe les données des trois ensembles de fiabilités.

H-2 MODELES CNN :

Après la démocratisation des CNNs avec AlexNet en 2012, de nombreuses architectures ont vu le jour (Howard *et al.* 2017; Szegedy *et al.* 2017; Huang *et al.* 2017; Tan & Le 2019). Se concentrant sur la faisabilité et l'identification des biais, ce travail utilise des modèles basés sur des architectures éprouvées. Par le nombre limité de photos, il est nécessaire d'utiliser des techniques d'augmentation de données pour simuler et généraliser divers scénarios réels.

H-2.1 ARCHITECTURES ET HYPERPARAMETRES :

Les architectures privilégiées comprennent de nombreuses couches (modèles profonds). Cette profondeur est utile pour détecter les caractères déterminants à plusieurs échelles. Cependant, de nombreuses couches peuvent entraîner le *vanishing gradient problem* (Hochreiter 1998) ou encore un surapprentissage (mauvaise généralisation sur des données inconnues) important et trop rapide. De plus, un modèle très profond demande des ressources conséquentes et un long temps d'entraînement. Tous les




Fig. 8: Schéma du fonctionnement d'un conteneur Nvidia modifié d'après <https://www.adaltas.com/fr/2022/03/24/nvidia-docker/>. Bien que plus gourmand en puissance de calcul, cette mise en place est compatible sur toutes les distributions populaires ainsi que sur les derniers drivers Nvidia.

modèles sont entraînés sur une carte graphique (GPU) NVIDIA RTX 5070 12 Go dans un conteneur NVIDIA NGC TensorFlow version 25.02 2025 (<https://catalog.ngc.nvidia.com/orgs/nvidia/containers/tensorflow>) (Fig. 8). Les modèles profonds mais parcimonieux en ressources sont privilégiés pour permettre une accessibilité à tout type d'équipement.

Plusieurs techniques sont mises en place à différentes échelles pour faciliter l'entraînement avec peu de données :

Résolution des photos

Les photos d'entrée sont redimensionnées avec un ratio 1:1 hauteur/largeur. Leur taille est un facteur direct du temps d'entraînement. En général, les architectures récentes sont testées sur des images allant de 32 x 32 pixels jusqu'à 600 x 600 pixels. Des images à résolution trop basse risquent de ne pas contenir assez de caractères déterminants, l'inverse entraîne un temps d'entraînement plus important. Pour ces travaux, les résolutions 128x 128, 256 x 256, 380 x 380 et 512 x 512 sont privilégiées (Fig. 9).




Fig. 9: Exemple d'un spécimen du genre *Sagenites* (Mojsisovics, 1879) redimensionné à 512x512, 380x380 et 256x256 pixels.

Optimiseurs

Les optimiseurs ajustent la valeur des poids lors du calcul du gradient de la fonction de perte. SGD (Gradient Stochastique Descendant) (Robbins & Monro 1951) est l'optimiseur historique pour les problèmes de Machine Learning. Cependant, les optimiseurs Adam (Kingma & Ba 2015) et RMSprop (Hinton *et al.* 2012), plus rapides à converger et moins sujets à des minima locaux, sont désormais la norme. Des techniques de perte de poids (Krogh & Hertz 1991) et de régularisation L2 (Cortes *et al.* 2009) (*weight decay* / *L2 regularization*) sont applicables pour réduire le surapprentissage. Pour ce travail, l'implémentation de Keras (<https://github.com/keras-team/keras>) de l'optimiseur RMSprop sans perte de poids et sans régularisation est utilisée pour simplifier le nombre d'hyperparamètres à tester.

Les lots (minibatch)

Pour accélérer le processus d'apprentissage, il est commun d'utiliser des lots d'images de taille variable (Radiuk 2017). La taille d'un lot d'images influe directement la capacité d'apprentissage d'un modèle. Les poids sont mis à jour pour chaque lot : plus les lots sont petits, plus l'apprentissage est graduel, mais plus il est chronophage. Dans le cadre de cette étude, des tailles de lots faibles (8/16/32 images) sont privilégiées en raison de la quantité de données et du matériel limité.

Epoques

Le nombre d'époques correspond au nombre de passes sur l'entièreté de l'ensemble « entraînement ». À chaque fin d'époque, le taux de prédiction et la perte globale sont calculés sur les ensembles « entraînement » et « validation ». Pour obtenir un taux de prédiction satisfaisant, plusieurs dizaines ou centaines d'époques sont nécessaires. Le suivi de ces taux

peut être utile pour des arrêts anticipés lorsque les scores stagnent ou régressent à cause du surapprentissage.

Le dropout

Le dropout, ou abandon de neurones (Srivastava *et al.* 2014), est une technique qui réduit l'impact du surapprentissage et induit une meilleure généralisation. Le principe consiste à remettre à zéro un pourcentage aléatoire de connexions par couche lors de l'apprentissage (Fig. 10). Cette technique de régularisation force le modèle à s'appuyer sur différents réseaux de neurones et donc sur différents caractères diagnostiques. Dans ce travail, des valeurs de 0.2 à 0.3 sont privilégiées.




Fig. 10: Modifié d'après Srivastava *et al.* (2014). Exemple du 'dropout' appliqué à un réseau neuronal.

Réseau neuronal résiduel et compression/excitation

Pour apprendre des caractères distinctifs et augmenter sa précision, un modèle a besoin d'être profond (beaucoup de couches). Cependant, plus le nombre de couches est important, plus le modèle fait face au *vanishing gradient problem*. Les réseaux neuronaux résiduels, initialement implémentés dans le modèle ResNet (He *et al.* 2016), servent à « sauter » des couches de manière à virtuellement réduire la profondeur du modèle. D'une autre manière, les blocs compression/excitation, implémentés dans l'architecture MobileNetV2 (Howard *et al.* 2017), jouent sur des informations non spatiales par la compression indépendante de chaque canal de couleur (RGB) (Fig. 11). Après une évaluation par couche dense et activation, le résultat est appliqué sur chaque canal de couleur. Ces techniques réduisent la dégradation et le surapprentissage tout en gardant un taux de prédiction élevé.




Fig. 11: Modifié d'après Tan *et al.* (2019). Exemple d'un bloque résiduel (à gauche) et de sa contrepartie excitation/compression (à droite).

Le taux d'apprentissage

Le taux d'apprentissage représente le pas lors de l'entraînement du modèle. Dans un espace à plusieurs milliers de dimensions, un taux d'apprentissage trop faible restera bloqué dans un minimum local (Fig. 12). Au contraire, un taux d'apprentissage trop élevé n'arrivera jamais à un minimum global car trop imprécis. Le taux d'apprentissage fait aussi varier la vitesse de convergence d'un modèle et donc son temps d'apprentissage. Pour ce travail, le taux d'apprentissage par défaut est de 0.0001 sauf contre-indication.




Fig. 12: Modifié d'après Chollet (2021), exemple de l'effet du taux d'apprentissage sur un espace en 2 dimensions.

Les normalisations de lots

Parmi les techniques d'accélération d'apprentissages, la normalisation des lots (*batch normalization*) (Ioffe & Szegedy 2015) est souvent utilisée. Le principe est basé sur la normalisation des données d'entrée centrées sur une moyenne égale à zéro (e.g. des valeurs RGB codées de 0 à 255 sont normalisées entre 0 et 1). Pour la normalisation de lots, un principe similaire est appliqué généralement avant ou après les couches d'activation. Empiriquement, cela donne de meilleurs résultats et fait converger le modèle plus rapidement. Il est supposé que cette technique réduit les effets de « canyon » (Fig. 13) où la rétropropagation resterait bloquée longtemps lors de l'apprentissage.




Fig. 13: Modifié d'après Hinton et al. (2012). Exemple d'un effet « canyon » dans un espace en deux dimensions. Un taux d'apprentissage trop élevé empêche une convergence rapide. Un effet « crête » est aussi possible.

Le transfert d'apprentissage

C'est une technique très utilisée pour compenser le faible volume de données et accélérer l'apprentissage (Pan & Yang 2010). Le principe est simple : transférer ce qu'un modèle a appris vers un autre spécialisé dans une tâche différente (Fig. 14). Un modèle est construit sur une architecture déjà entraînée (e.g. l'architecture ResNet sur les données ImageNet). Les couches supérieures et inférieures sont adaptées aux nouveaux jeux de données tandis que les poids sont gelés sur le reste des couches du modèle pré-entraîné. Après plusieurs époques d'entraînement initial, les poids sont dégelés pour quelques époques à un taux d'apprentissage plus faible (généralement dix fois moins que le taux initial). Cela fait converger le modèle dans son entièreté mais sur un temps plus rapide que sur une architecture classique. Cependant, la capacité de transférer l'apprentissage d'un modèle dépend du sujet du nouvel apprentissage. Un modèle prévu pour reconnaître des chiffres transférera probablement moins bien sur une base de données avec des photos de chiens. À l'inverse, un modèle entraîné sur des photos d'animaux transférera plus facilement sur un modèle chargé de reconnaître des espèces de chiens.




Fig. 14: Modifié d'après Abushawish et al. (2024). Schéma d'un transfert d'apprentissage d'une architecture construit pour ImageNet vers une architecture avec un objectif différent (ici sur des céphalopodes).

K-fold-cross validation

La faible quantité de données pose une problématique essentielle sur la représentation des ensembles « entraînement », « validation » et « test ». Lors de l'entraînement, il se peut que les données de validation ne soient pas représentatives des autres ensembles (e.g. aucune représentation d'illustration ancienne dans un des ensembles), entraînant une dissociation entre l'entraînement et le résultat. La validation croisée à N-plis pallie ce problème en entraînant les mêmes modèles avec différentes fractions de données (Raschka 2018) (Fig. 15). Le N de N-plis représente le nombre de fractionnements. Un N-plis de 3 revient à entraîner trois modèles ayant chacun un tiers de données différent pour la validation et deux tiers pour l'entraînement. Plus les scores finaux sont éloignés, moins les ensembles sont représentatifs les uns des autres. Cette technique induit des résultats plus robustes (moyenne de chaque pli), mais est très rapidement chronophage (entraînement de multiples modèles au lieu d'un seul).




Fig. 15: Modifié d'après Haden (<https://medium.com/data-science/how-to-cross-validation-with-time-series-data-9802a06272c6>). Schéma d'une validation croisée à 5 plis.

H-2.2 AUGMENTATION :

La couleur n'étant pas déterminante dans l'identification des spécimens, les images sont converties en nuances de gris. Pour appliquer un transfert d'apprentissage, les données en nuances de gris sont dupliquées sur trois couches pour simuler des données RGB.

La préservation des fossiles est très variable et deux fossiles d'une même espèce peuvent rendre très différemment en photo. De même, les conditions photographiques peuvent être très variables au sein même d'une publication. Il est donc intéressant d'augmenter les photos d'entrée à travers différents filtres. Ces augmentations vont d'un changement de luminosité à de la déformation d'images. Il est cependant important d'être parcimonieux sur ces augmentations au risque de détruire des informations utiles au modèle.

Dans ce travail, plusieurs augmentations simples sont utilisées :

Luminosité et contraste

La prise de photos en environnement difficile est simulée par une variabilité aléatoire de la luminosité et du contraste (Fig. 16). Les augmentations sont réglées sur un facteur de 0.2 avec les fonctions `tf.keras.layers.RandomContrast()` et `tf.keras.layers.RandomBrightness()`.




Fig. 16: Exemples d'itérations d'une même photo après augmentations.

Rotation et retournement

Certaines publications présentent des spécimens positionnés de manière similaire. Pour éviter que cela biaise l'apprentissage, une rotation aléatoire est appliquée sur les images d'entrée (Fig. 16). L'augmentation rotative est réglée sur 0.2 et le retournement est horizontal avec les fonctions `tf.keras.layers.RandomFlip()` et `tf.keras.layers.RandomRotation()`.

H-2.3 ARCHITECTURES RETENUES

Par les nombreuses techniques évoquées ci-dessus, trois architectures sont retenues dans le but de couvrir un large spectre de situations : MobileNetV3 (Howard *et al.* 2019), léger et intégrant les techniques les plus récentes ; InceptionResNetV2 (Szegedy *et al.* 2017), plus lourde et plus ancienne ; EfficientNetV2 (Tan & Le 2019), récente, efficace et facilement échelonnable selon la tâche. Toutes ces architectures seront combinées avec un transfert d'apprentissage pour accélérer l'entraînement des modèles.

H-2.4 LES AUTRES ARCHITECTURES ML :

Les CNNs classiques sont les plus utilisés pour la classification d'objets. Cependant, de nombreuses autres alternatives existent avec leurs avantages et inconvénients.

Lors de tâches de classification, l'étiquetage des différentes images peut être fastidieux. Contrairement à ce travail « supervisé », d'autres modèles peuvent utiliser des images partiellement ou non étiquetées. C'est de l'apprentissage « semi-supervisé » ou « non supervisé ». L'intérêt repose principalement sur le gain de temps lors de bases de données très importantes. Ce genre d'apprentissage est plus approprié pour distinguer des clusters ou des regroupements, ce qui est moins nécessaire dans le cadre de cette étude.

Dans l'apprentissage supervisé, des réseaux neuronaux siamois (Bromley *et al.* 1993) seraient un bon candidat pour l'identification de spécimens fossiles. Ces architectures déterminent un taux de similitude à partir d'une image donnée. Cependant, la conservation d'un spécimen par rapport à un autre induit une trop grande différence, ce qui est moins pertinent pour ce travail.

En 2017, les Transformers (Vaswani *et al.* 2017), une architecture basée sur l'attention, supplantent les anciennes méthodes utilisées pour le NLP (Natural Language Processing) (Turing 1950). Quelques années plus tard, ils sont appliqués à la classification d'images (Dosovitskiy *et al.* 2020) et performant mieux que les CNNs dans certaines conditions. Ces architectures Transformers sont dépendantes de la quantité de données. Les CNNs, plus efficaces à entraîner et plus performants sur des bases de données limitées, sont ici privilégiés.

H-3 INTERPRETATION :

Les CNNs sont réputés pour leur difficulté à interpréter leurs comportements et leurs résultats, en raison de leur apprentissage et inférence dites « boîte noire ». Cependant, les CNNs dans le domaine de la vision par ordinateur possèdent diverses méthodes d'interprétabilité puissantes (Zhang *et al.* 2021). Ces techniques offrent une vision multi-échelle du modèle (*e.g.* courbe d'apprentissage) à la photo (*e.g.* Grad-CAM), en passant par la classe (*e.g.* matrice de confusion). Toutes ces méthodes sont testées sur l'ensemble « test » des bases de données, sauf contre-indication.

H-3.1 COURBE D'APPRENTISSAGE

Un graphique rapportant la précision et la perte par rapport aux époques est un bon indicateur de l'apprentissage du modèle. Il est attendu que la courbe de l'ensemble « validation » suive

celle de l'ensemble « entraînement ». Une courbe en dents de scie est symptôme d'hyperparamètres mal réglés (*e.g.* taux d'apprentissage trop agressif), tandis qu'un découplage des deux ensembles est un signe de surapprentissage. Deux valeurs « *accuracy* » et « *loss* » (« précision » et « perte » respectivement) sont mesurées et reportées sur les graphiques.

H-3.2 GRAD-CAM, GUIDED GRAD-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping) et Guided Grad-CAM (Selvaraju *et al.* 2017) sont des techniques de visualisation interprétative. Pour le gradient d'une classe définie, Grad-CAM évalue son effet sur les cartes de caractéristiques (*feature map*). Avec la rétropropagation guidée, Guided Grad-CAM propose une analyse précise des bords et reliefs des objets pixel par pixel. Cela montre les endroits considérés comme important pour la prédiction du modèle. Ces méthodes sont appliquées à la dernière couche d'activation pour mettre en valeur un maximum d'informations.

H-3.3 LIME

LIME (Local Interpretable Model-agnostic Explanations) (Ribeiro *et al.* 2016) est une technique testant la fidélité locale. Une image à l'étiquetage connu est modifiée aléatoirement par la suppression de superpixels (ensembles de pixels prédéfinis par une méthode de segmentation, *e.g.* SLIC (Achanta *et al.* 2012)). Pour chaque super-pixel différent, une nouvelle image est testée sur le modèle. Ainsi, plus le nombre d'itérations est important, plus la probabilité qu'un superpixel contribue ou non à l'identification est estimée. Cette technique permet de détecter ce que le modèle considère comme un superpixel contribuant ou non à l'identification.

H-3.4 T-SNE

L'algorithme t-SNE (t-distributed Stochastic Neighbor Embedding) (Maaten & Hinton 2008) est un réducteur de dimension similaire à l'ACP (Pearson 1901). Il est intéressant pour visualiser et estimer la capacité d'un modèle à séparer correctement chaque classe. Il est privilégié dans les domaines de l'intelligence artificielle par sa capacité à préserver la relation spatiale des points dans les dimensions inférieures. En contrepartie, son calcul est lourd et demandant. L'algorithme t-SNE demande une valeur de perplexité définissant les interactions entre l'aspect global et local des données. N'ayant pas de valeur « parfaite » de perplexité, plusieurs t-SNE à perplexités variables seront réalisés pour chaque modèles. L'algorithme t-SNE est appliqué sur l'avant dernière couche des modèles.

H-3.5 MATRICE DE CONFUSION

La matrice de confusion permet de visualiser de manière plus fine les classes une à une sur leur bonne et mauvaise prédiction. Cette matrice met en opposition les prédictions aux vrais étiquetages.

H-3.6 ROC-AUC

Les courbes ROC-AUC (Receiver Operating Characteristic – Area Under Curve) (Delacour *et al.* 2005) évaluent les faux positifs contre les vrais positifs. Elle est utilisée sous sa forme OvR (One versus the Rest) en conjugaison avec la matrice de confusion pour une analyse plus fine de chaque classe. Les scores AUC sont intéressants pour la représentation de leur sensibilité au faux positif et sont donc privilégiés dans ce mémoire.

I-RESULTATS :

Tous les résultats présentés ici sont les meilleurs scores des ensembles « validation » lors de l'entraînement des modèles, sauf contre-indication. Le score « entraînement » est prolongé jusqu'à être proche de 100 %, mais les scores de perte et de précision de l'ensemble validation, plus représentatifs, peuvent décroître lors d'un surapprentissage trop intense.

I-1 LES BASES DE DONNEES FIABILITES

Les modèles de fiabilité sont entraînés sur l'architecture InceptionResNetV2 avec quatre résolutions d'images différentes (128 x 128, 256 x 256, 350 x 350, 512 x 512) (Fig. 17). Les hyperparamètres restent les mêmes à travers tous les modèles :

- Taux d'apprentissage : 0.0001 (0.00001 après transfert)
- Dropout : 0.2
- Epoques initiales : 100
- Epoques transfert d'apprentissage : 100
- Taille de lots : 16
- Teintes de gris




Fig. 17: Courbe d'entraînement des modèles InceptionResNetV2 380x380 très fiable (à gauche), fiable (au milieu), peu fiable (à droite). Remarquez le découplage entre la précision de l'entraînement et de la validation après le transfert d'apprentissage. C'est un symptôme typique de surapprentissage. L'impact est visible sur les courbes des pertes avec des variations plus intenses à partir des 110 époques.

La résolution est un facteur limitant, la résolution 128 x 128 étant globalement moins précise comparée aux résolutions supérieures. À l'inverse, des résolutions trop hautes augmentent le temps d'entraînement pour un résultat similaire aux résolutions inférieures. Ce comportement s'explique en partie par l'architecture, optimisée pour des résolutions maximales de 299 x 299 pixels (Richter *et al.* 2021). De même, la résolution moyenne des bases de données est parfois inférieure aux grandes résolutions utilisées et n'apporte pas de nouvelles informations (e.g. 374 par 258 pixels de moyenne pour la base de données « peu fiable »).

Les modèles « peu fiable » présentent les meilleurs scores avec plus de 85 % de bonnes prédictions sur l'ensemble « test ». Les bases de données « fiable » et « très fiable » suivent respectivement avec 76 % et 73 % (Tableau 6).

La différence de résultats entre les ensembles « validation » et « test » est associable aux quantités de données assez faibles et aux tailles de lots (mise à jour des poids lors de l'entraînement moins fréquente) relativement grandes. Certains genres ayant 100 images se retrouvent avec un ensemble « test » de 5 images (moins représentatif). Ces modèles montrent une tendance entre les trois fiabilités plus qu'une application réelle.

	Très fiable			Fiable			Peu Fiable		
	Entrainement	Validation	Test	Entrainement	Validation	Test	Entrainement	Validation	Test
128x128									
InceptionResnetV2	98,28 %	58,66 %	59,89 %	99,52 %	69,07 %	72,91 %	99,63 %	77,32 %	78,12 %
256x256									
InceptionResnetV2	97,87 %	66,78 %	71,35 %	99,74 %	73,02 %	76,04 %	99,58 %	78,68 %	82,81 %
350x350									
InceptionResnetV2	98,11 %	69,17 %	73,43 %	99,04 %	70,61 %	76,04 %	99,75 %	81,14 %	85,00 %
512x512									
InceptionResnetV2	97,97 %	67,11 %	72,11 %	97,47 %	67,10 %	67,70 %	98,72 %	78,57 %	80,00 %
Nombre de classes (genres)	32			24			13		

Tableau 6: Résultats des modèles de fiabilités publications

Les modèles de fiabilité normés sont entraînés avec les mêmes paramètres sur une résolution de 350 x 350 pixels, en utilisant une validation croisée à 5 plis (Fig. 18). Une moyenne est calculée pour chaque ensemble de fiabilité. Ici, les résultats des ensembles « test » sont les plus représentatifs d'une situation générale (mixte des trois bases de données de fiabilité).



Fig. 18: Courbe d'entraînement d'un des plis des modèles EfficientNetB4 380x380 très fiable (à gauche), fiable (au milieu), peu fiable (à droite). Les valeurs sont plus variables que celles non normées, montrant bien la nécessité d'une validation croisée.

La base de données « très fiable » normée est en moyenne plus performante avec un score de 62,89 % contre 62,53 % et 59,63 % pour les données « fiable » et « peu fiable » sur l'ensemble « test » (Tableau 7).

	Très fiable			Fiable			Peu fiable		
	Entrainement	Validation	Test	Entrainement	Validation	Test	Entrainement	Validation	Test
Plis 1	92,54 %	97,72 %	65,56 %	94,50 %	91,11 %	66,66 %	98,03 %	93,33 %	64,15 %
Plis 2	77,64 %	79,54 %	60,66 %	94,11 %	95,55 %	66,78 %	94,11 %	93,33 %	60,66 %
Plis 3	99,62 %	82,75 %	64,82 %	100 %	86,66 %	65,74 %	100 %	80,00 %	54,59 %
Plis 4	94,50 %	97,72 %	63,54 %	84,70 %	73,33 %	58,21 %	92,15 %	88,88 %	60,78 %
Plis 5	81,96 %	81,81 %	59,86 %	78,03 %	68,88 %	55,26 %	96,07 %	95,55 %	57,96 %
Moyenne	89,25 %	87,91 %	62,89 %	90,27 %	83,11 %	62,53 %	96,08 %	90,22 %	59,63 %
Ecart Type	7,56	7,85	2,10	7,12	9,60	4,64	2,35	4,62	2,68
Nombres de classes (genres)	4								

Tableau 7: Résultats des modèles de fiabilités publications normées

I-2 LES BASES DE DONNEES VUES

Ce test cherche à évaluer l'impact de la vue d'un spécimen sur la capacité d'identification d'un modèle. L'architecture utilisée est EfficientNet dans sa version B4 plus légère. Les hyperparamètres sont les suivants :

- Taux d'apprentissage : 0.0001 (0.00001 après transfert)

- Dropout : 0.3
- Epoques initiales : 30
- Epoques transfert d'apprentissage : 25
- Taille de lots : 10
- Teintes de gris

Le dropout est augmenté à 0.3 suivant les recommandations de Tan & Le (2019), auteurs de l'architecture EfficientNet.

Les résultats sont similaires : les ensembles test présentent des taux de prédiction avoisinant de 83 % à 86 %, le score le plus faible étant attribué à la vue transversale. La différence entre l'ensemble « validation » et « test » est moins marquée ici, la limite basse de photos par genre étant plus élevée (Tableau 8).

	Latéral			Transversal			Mixtes		
	Entraînement	Validation	Test	Entraînement	Validation	Test	Entraînement	Validation	Test
350*350 efficientNetB4	98,16 %	81,13 %	86,66 %	96,36 %	85,51 %	83,33 %	94,51 %	81,32 %	85,55 %
Nombres de classes (genres)	11								

Tableau 8: Résultats des modèles de vues

I-3 LA BASE DE DONNEES FRAGMENTS

L'architecture et les hyperparamètres sont identiques au test précédent. L'objectif est d'obtenir un score similaire entre l'ensemble « validation » et « test » (Fig. 19).

L'ensemble « test » est uniquement composé de fragments, contrairement aux ensembles « entraînement » et « validation ». Cela résulte en une différence marquée au niveau des taux de prédiction, avec plus de 18 points en deçà de l'ensemble « validation » pour l'ensemble « test » (Tableau 9).

	Fragments		
	Entraînement	Validation	Test
350*350 efficientNetB4	91,52 %	78,43 %	59,67 %
Nombres de classes (genres)	11		

Tableau 9: Résultats du modèle fragments




Fig. 19: Courbes d'entraînements du modèle fragments.

I-4 LES BASES DE DONNEES MIXTES

La base de données mixte et mixte+gbif présente le plus d'intérêt avec un nombre conséquent de genres à déterminer. Trois architectures (InceptionResNetV2, MobileNetV3 et EfficientNetV2M) sont testées avec les hyperparamètres suivants :

- Taux d'apprentissage : 0.0001 (0.00001 après transfert)
- Dropout : 0.3
- Époques initiales : 30
- Époques transfert d'apprentissage : 50
- Taille de lots : 8
- Teintes de gris/couleur

A noter que MobileNetV3L et le modèles InceptionResNetV2 ont montré une grande difficulté à converger et a donc amener à doubler leur nombre d'époques pour l'entraînement.

Les meilleurs scores mixte et mixte+gbif 100 sur les genres sont détenus par l'architecture EfficientNetV2M avec respectivement 62.3% et 68.61% sur la version RGB (61.05% et 62.77% en nuance de gris). Cette architecture pensée pour la mise à l'échelle performe sur des résolutions différentes de manière équivalente. InceptionResNetV2 suis avec plus de 60% de bonnes prédictions. Sur les 3 prédictions les plus probables, EfficientNetV2M (380x380 et 512x512) et InceptionResNetV2 montre un score supérieur à 80%. MobileNetV3L, une architecture moins profonde, montre une limitation évidente avec 57,04% de bonne identification. Sa contrepartie mixte+gbif pointe un score de 60.25% (Tableau 10).

Pour les deux bases de données limitées à 200 et 300 images minimum par genres, les scores atteignent respectivement 76% et 79% avec l'architecture EfficientNetV2M.

Avec les bases de données 'espèces', L'architecture EfficientnetV2M atteint le score de 77%. Le top 3 prédiction pointe à 93,18% pour la base de données mixte+gbif.

Dataset_mixte_gen_100					Dataset_mixte+gbif_gen_100			
	Entrainement	Validation	Test	Test top 3	Entrainement	Validation	Test	Test top 3
380x380 EfficientNetV2m RGB	98,15%	63,61%	62,63%	80,35%	97,34%	65,48%	68,61%	85,05%
380x380 EfficientNetV2m	97,75%	62,47%	61,05%	82,63%	95,78%	63,65%	62,77%	82,20%
380x380 InceptionResNetV2	93,91%	60,53%	60,38%	80,98%	97,17%	62,40%	61,68%	80,29%
380x380 MobileNetV3	95,62%	59,43%	57,04%	77,64%	95,17%	61,28%	60,25%	79,57%
256x256 EfficientNetV2m	97,68%	62,50%	61,26%	79,40%				
512x512 EfficientNetV2m	93,46 %	62,34%	61,40 %	81,05 %				
Nombres de genres	82				95			
Dataset_mixte_gen_200					Dataset_mixte+gbif_gen_200			
380x380 EfficientNetV2m	98,92%	75,83%	76,66%	90,83%	99,08%	75,46%	76,41%	90,32%
Nombres de genres	31				36			
Dataset_mixte_gen_300					Dataset_mixte+gbif_gen_300			
380x380 EfficientNetV2m	98,85%	77,85%	79,71 %	94,92%	99,03%	80,34%	79,90%	94,85%
Nombres de genres	20				24			
Dataset_mixte_sp_100					Dataset_mixte+gbif_sp_100			
380x380 EfficientNetV2m	99,14 %	73,45%	77,49 %	88,74 %	99,58 %	76,47%	77,27 %	93,18 %
Nombres d'espèces	32				34			

Tableau 10: Résultats des modèles mixte et mixte+gbif

J-DISCUSSION :

Cette partie aborde de manière la plus exhaustive possible les différents biais associés aux résultats des différents modèles jusque-là présentés.

J-1 BIAIS DE COLLECTE

Les bases de données sont agrégées à partir d'illustrations de publications. Cela entraîne une dépendance à la rigueur des multiples auteurs.

J-1.1 BIAIS SPATIAL ET CHRONOLOGIQUE

Sur le plan spatial, la collecte des spécimens est hétérogène avec des pays plus représentés (Fig. 20).




Fig. 20: Modifié d'après Gbif (<https://www.gbif.org/fr/>), répartition des céphalopodes fossiles sur le globe. Leur concentration est principalement située en Europe et en Amérique du Nord.

Sur le plan chronologique, les spécimens ne sont pas répartis de manière homogène. Ces biais sont moins impactant dans le cadre de l'utilisation de ces bases de données et sont ignorés.

J-1.2 BIAIS D'INTERET

La plupart des publications privilégient les spécimens comportant le plus de caractères déterminants et donc généralement les plus complets. Bien que ce comportement soit utile lors de l'entraînement des CNNs pour capter un maximum de caractères discriminants, il pose la question de la **préservation** et de la **fragmentation** des spécimens (Fig. 21). Cette problématique regroupe aussi la préparation et l'**altération** des spécimens (*e.g.* loge colorée). L'aspect composite lié à certaines préparations est considéré comme peu impactant dans le contexte de ce travail.




Fig. 21: Exemple de spécimens fragmentés avec leur prédiction et leur vraie identification.

Les résultats de la base de données « fragments » montrent une difficulté du modèle à reconnaître ces derniers. La matrice de confusion précise que le genre *Juvenites* (Smith, 1927) est particulièrement impacté, avec seulement 31 % de bonnes prédictions, et est confondu avec *Owenites* (Hyatt & Smith, 1905) dans 23 % des cas. Les genres *Meekoceras* (Hyatt, 1879), *Ophiceras* (Griesbach, 1880) et *Owenites* (Hyatt & Smith, 1905) présentent une sensibilité au faux positifs plus marquée, avec des scores AUC respectifs de 0.84, 0.87 et 0.83 (Fig. 22).

L'algorithme Grad-CAM montre une dépendance importante à la morphologie des tours des spécimens dans l'identification. Certains caractères semblent mieux retenus (*e.g.* ornementation de la carène pour *Trachyceras* (Laube, 1869)). A contrario, des spécimens très **fragmentés** (moins de 25%) assez **lisses** semble être un **exercice difficile** pour le modèle (Fig. 23). Le modèle rencontre des difficultés à faire abstraction des caractéristiques de grande échelle (forme




Fig. 22: (À gauche) matrice de confusion et (à droite) courbe ROC avec scores AUC du modèle fragments.

générale du spécimen) mais semble **moins sensible** aux **colorations des loges** ou autres altérations **non déformantes**. Il serait intéressant d'incorporer plus de données fragmentées ou des augmentations de recadrage aléatoire (initialement rejetées pour éviter des pertes de caractères trop importantes).

Les modèles sont capables de reconnaître certains caractères déterminant pour les appliquer à leur contrepartie fragmentée. Cependant, c'est au détriment d'une **capacité d'identification affaiblie**.




Fig. 23: Guided-Grad-CAM et Grad CAM de trois spécimens *Dieneroceras* (Spath, 1934), *Trachyceras* (Laube, 1869) et *Meekoceras* (Hyatt, 1879). Notez la mauvaise prédiction de *Meekoceras* (Hyatt, 1879) en *Hemiprionites* (Spath, 1929), sur un spécimen très fragmenté et peu ornementé.

J-2 IDENTIFICATION FINE ET VARIATION INTRA-SPECIFIQUE

Les modèles entraînés sur les bases de données « mixte_sp » et « mixte+gbif_sp » donnent une estimation de la capacité d'identification sur des caractères déterminants très similaire au niveau spécifique. Leur matrice de confusion est marquée par une difficulté d'identification entre les espèces d'un même genre (*e.g.* *O. koeneni* (Hyatt & Smith, 1905) vs *O. simplex* (Welter, 1922)). Les scores AUC dans leur configuration OvR sont moins représentatifs dans ce cas. Cette confusion se retrouve dans les graphiques t-SNE, notamment avec *A. kingianus* (Waagen, 1895) et *A. multiformis* (Welter, 1922) très proches (Fig. 24, Fig. 25). L'identification au niveau de l'espèce reste un défi dans ce cas de figure avec **peu de données** et des **qualités d'identification variables**.

Certaines espèces de céphalopodes présentent des **dimorphismes sexuels** entre macroconque et microconque. L'**ontogénie** est aussi à prendre en compte avec des morphologies différentes pour les spécimens juvéniles. Ces cas de figure n'ont pas pu être testés dans le cadre de ce travail, principalement par manque de temps et de données. Pour ce qui est du dimorphisme sexuel, il s'exprime généralement par une différence de taille et d'ornementation (Landman *et al.* 1996). Il est moins présent chez les céphalopodes de la période triasique et est peu impactant pour cette étude. La difficulté des variations morphologiques réside principalement dans leur représentation par rapport au reste des images d'une même classe. Les **microconques**, généralement plus petits, sont impactés par des **biais de collecte**. Pour ce qui est des variations uniquement exprimées par la **différence de taille**, les CNNs fonctionnant en **multi-échelle** ne sont **pas affectés**. L'impact d'**ornementations** différentes est plus difficile à estimer. Ces

formes pourraient **affecter négativement** les modèles d'une manière **similaire au test de fragmentation**.

Il est donc difficile pour les CNNs de bien **différencier les spécimens** au **niveau spécifique** sans plus de données comportant les subtilités des variations intraspécifiques, dimorphiques et ontogéniques.



Fig. 24: Graphique t-SNE des modèles mixtes+gbif espèces (en haut) et mixtes (en bas). Les données à observer sont les espèces appartenant à un même genre. Par exemple, une concentration des points de *A.kingianus* (Waagen, 1895) et *A.multiformis* (Welter, 1922) forme un ensemble indissociable (cercle en pointillé) démontrant la difficulté des modèles à les différencier. Ici, les scores et les données étant assez limités, il est difficile d'en tirer des conclusions plus poussées.




Fig. 25: Matrices de confusion des modèles mixtes+gbif_sp (en haut) et mixtes_sp (en bas). Les espèces d'un même genre sont encadrées en bleu. Notez la confusion de P.compressa (Hyatt & Smith, 1905) en A.acutus (Hyatt & Smith, 1905). Les quantités de données de P.compressa (Hyatt & Smith, 1905) sont faibles (100 photos). L'ensemble 'test' (5% soit 5 photos) aléatoirement réparti ne présente 'malheureusement' que des vues transversales confondues avec celle de A.acutus (Hyatt & Smith, 1905) (aux caractères déterminants très proches).

J-3 BIAIS DE LA METHODE

J-3.1 BIAIS DE CADRAGE

Un problème récurrent dans l'identification par CNNs est l'utilisation transversale d'autres caractères que ceux recherchés. Ce biais est décelable sur les tests de fiabilité. Au premier abord, on supposerait un score de bonnes prédictions croissant avec la fiabilité. Cependant, l'ensemble « peu fiable » montre de meilleurs scores que les autres. Le nombre de classes est un premier élément d'explication, avec 13 genres à identifier pour l'ensemble « peu fiable » contre 32 pour « très fiable ». Le modèle « peu fiable » a plus de chance ($\approx 7\%$) d'être correctement classé aléatoirement que l'ensemble « très fiable » ($\approx 3\%$). Cependant, les écarts sont trop importants pour qu'il s'agisse de la seule explication.

L'algorithme Grad-CAM et LIME mettent en évidence un nombre important d'images avec une attention du modèle portée sur **l'arrière-plan** ou les **annotations** (Fig. 26, Fig. 27). Il semble que cela soit particulièrement impactant sur les données « peu fiable ». Cet ensemble, principalement composé de publications anciennes, comporte des teintes jaunies en arrière-plan ainsi que des polices d'écriture parfois uniques à la publication. Ces informations permettent au modèle de faire de la **prédiction transversale**, en particulier lorsque beaucoup de spécimens proviennent d'une même publication (e.g. le genre *Trachyceras* (Laube, 1869) représenté de nombreuses fois dans Mojsisovics 1893). L'ensemble « très fiable » est moins affecté par ce problème. Généralement provenant de publications plus récentes et publiées en format numérique, les **arrière-plans** et les **polices** sont plus **normés** et donc **moins sujets à ce biais**. L'ensemble « fiable » est un mixte, ce qui se reflète bien dans les résultats.




Fig. 26: Guided Grad-CAM et Grad-CAM montrant l'attention du modèle dispersée sur l'arrière-plan et les annotations.




Fig. 27: LIME montrant une attention positive (vert) et négative (rouge) sur l'arrière-plan des photos. Les deux photos à gauche sont les prédictions les plus probables. Les deux photos à droite sont les moins probables.

Une méthode possible pour limiter ce biais est d'entraîner un modèle de détection d'objet (e.g. Mask R-CNN (He *et al.* 2017)) spécialisé pour les ammonites. De cette manière, il est aisé de supprimer l'arrière-plan pour ne garder que le spécimen. Une autre méthode, moins coûteuse, est de **diversifier les fonds**, ce qui a été partiellement mis en place avec l'ajout des données Gbif plus diversifiées dans une base de données à part.

Ce biais est le plus préjudiciable dans le cas d'une identification voulue rigoureuse. Si la construction d'une base de données très fiable n'est pas possible, il est recommandé d'utiliser la méthode Grad-CAM facile et rapide à implémenter pour de meilleurs **éléments d'interprétations et de vérifications**.

J-3.2 BIAIS D'IDENTIFICATION

Les modèles de fiabilité normés évaluent l'impact de l'identification tout en limitant les biais de cadrage retrouvés dans les modèles de fiabilité non normés. L'écart entre les ensembles non normés est moins présent sur les normés. Malgré une tentative de lisser l'identification sur la base de données Gbif, une légère différence subsiste entre les ensembles.

Le modèle « très fiable » identifie mal *Ophiceras* (Griesbach, 1880) (score AUC 0.79). Les modèles « fiable » et « peu fiable » ont tendance à être mieux répartis. D'après le graphique t-SNE, *Anasibirites* (Waagen, 1895) est facilement différencié du reste. Une partie des *Tirolites* (Mojsisovics, 1879) est bien groupée. Les genres *Meekoceras* (Hyatt, 1879) et *Ophiceras* (Griesbach, 1880) sont mal différenciés par le modèle. Ces observations sont en accord avec les matrices de confusion des trois modèles. Il est possible que l'incertitude sur *Meekoceras* (Hyatt, 1879) et *Ophiceras* (Griesbach, 1880) soit due à une ornementation moins marquée que sur les deux autres genres. Les graphiques t-SNE apportent une information supplémentaire en montrant des ensembles de points assez étirés ou séparés en deux groupes de points. Il est probable que l'avant-dernière couche du modèle, dont l'algorithme t-SNE utilise, sépare encore bien les deux vues transversale et latérale (Fig. 28).




Fig. 28: Matrice de confusion, Courbe ROC-AUC et graphique t-SNE pour les modèles très fiable normés (à gauche), fiable normés (milieu) et peu fiable normés (à droite). Remarquez *Anasibirites* (Waagen, 1895) généralement bien différencié dans les graphiques t-SNE

Le bruit généré par une identification variable est ici testé sur quatre genres. L'impact à plus grande échelle est **difficilement estimable**. Les résultats étant déjà impactant sur ces genres, on estime que l'identification spécifique est également impactée.

La qualité d'identification est définitivement à prendre en compte dans ce genre d'exercice. Cet exemple est limité faute à une **quantité de données faible**. Avec un nombre de photos beaucoup plus important, il est probable que les écarts soient plus représentatifs et significatifs.

J-3.3 BIAIS DE REPRESENTATION

La représentation des spécimens a un impact direct sur le modèle. Dans le cadre de cette étude, les spécimens sont présents sous deux formes principales : la photographie et le dessin, en couleur ou en nuances de gris. De plus, les vues transversales et latérales des spécimens véhiculent une information différente et disparate.

La photographie est le médium le plus courant et donc le plus représentatif d'une utilisation réelle. Le dessin est présent dans les anciennes publications et est moins représenté dans les bases de données mixtes. Par le **dessin**, les auteurs mettent en valeur des caractères déterminants de manière exagérée, ce qui pose un **problème de généralisation** sur des données nouvelles. On note un double effet sur la base de données « peu fiable » avec une identification et une représentation des spécimens qui pénalisent le score de bonnes prédictions.

Sur une problématique similaire, la représentation en **couleur** ou en **nuances de gris** est impactante dans cette étude (62,77 % contre 68,61 % pour mixte+gbif). La couleur n'étant pas un critère diagnostique pour l'identification, il est important de porter une attention particulière dans les cas où les **différences de scores** seraient **trop importantes**. Avec les augmentations appliquées, il est aussi nécessaire d'être vigilant sur des identifications de spécimens se basant sur la **chiralité** (e.g. augmentation de retournement horizontal) (Hsiang *et al.* 2019).

Pour les différentes vues, les résultats sont proches, avec un avantage pour la vue latérale de 3,33 % par rapport à la vue transversale. Pour la vue transversale, *Meekoceras* (Hyatt, 1879) et *Xenoceltites* (Spath, 1930) sont les deux genres les moins bien identifiés sur la matrice de confusion, leur score AUC restant élevé (0.93 et 0.98 respectivement) (Fig. 30). L'algorithme Grad-CAM porte une attention appuyée à **l'ouverture des spécimens**.

Pour la vue latérale, *Meekoceras* (Hyatt, 1879) est aussi moins bien identifié (score AUC 0.94). Le modèle porte attention aux tours et aux dernières loges des spécimens. Les individus comportant des **côtes saillantes** sont aussi mis en avant par Grad-CAM. La morphologie des côtes et des tours est si importante pour le modèle que l'algorithme LIME montre sur certains spécimens une **contribution négative** sur les superpixels positionnés au niveau de **l'ombilic** (Fig. 29).

Ces comportements, pour les vues transversale ou latérale, se retrouvent de manière moins marquée sur l'ensemble « vue mixte ». Les vues Grad-CAM transversales et latérales montrent une attention du modèle mieux répartie sur tout le spécimen. La matrice de confusion et les courbes ROC-AUC sont **mieux équilibré**. La vue mixte prend en compte plus de caractères pour un score très similaire (85,55 % pour 11 genres) et une **capacité de généralisation** plus **intéressante**.




Fig. 30: Matrices de confusion et courbes ROC-AUC pour les modèles vus transversal (gauche), latéral (milieu) et mixte (droite).




Fig. 29: Guided Grad CAM, Grad CAM et LIME pour les vues latérales (gauche) et transversales (droite). La vue latérale Guided Grad-CAM de Meekoceras (Hyatt, 1879) porte une attention sur les sutures visibles. LIME montre que cette attention est détrimentaire à la prédiction.

Ce travail porte principalement sur les céphalopodes du Trias et n'a pas abordé la question des formes hétéromorphes, moins représentées à cette période. Par leur diversité morphologique, on peut supposer que les modèles porteraient plus d'attention sur leur ornementation, en particulier sur des spécimens à enroulement fortement irrégulier. Cela reste à tester comparativement à des morphologies similaires (e.g. céphalopodes à enroulement hélicoïdal contre gastéropodes).

La **multiplicité des vues** permet une **meilleure généralisation** de la reconnaissance des spécimens. La photographie reste la donnée à privilégier pour sa rapidité et simplicité.

J-3.4 DESEQUILIBRE ET QUANTITE DES DONNEES

Les CNNs dépendent de la quantité de données et de l'équilibre entre les classes à prédire. ImageNet présente pour 10 000 classes plus de 10 000 000 de photos, ce qui revient à une moyenne de 1000 images par classe. Dans le cadre de cette étude, 100 images par classe constituent une **quantité faible** et empêchent une meilleure généralisation, même avec des augmentations.

Le déséquilibre des données impacte très fortement les résultats, avec des classes sous-performantes par rapport à d'autres. Les modèles « **mixtes_100** » et « **mixtes+gbif_100** » sont affectés, montrant des scores moyen AUC **très faibles et inégal** (e.g. *Inyoites* (Hyatt & Smith, 1905) avec un score de 0.24 sur le modèle « mixtes+gbif »). À l'inverse, dès que la limite minimale de données est augmentée à **200** ou **300 images**, les scores AUC globaux sont **plus équilibrés et plus élevé** (Fig. 31).

Le cas des données libres d'accès Gbif était initialement prévu pour construire un modèle unique à comparer aux données des publications. Un problème est rapidement survenu lorsque deux genres (*Ammonites* (Bruguière, 1789) et *Orthoceras* (Bruguière, 1789)) comptaient pour 50 % (2324 sur 4594 photos) de la totalité des spécimens. Cela résultait en un modèle **très déséquilibré** envers ces deux genres.

Cette quantité de données impacte les méthodes interprétatives. Les graphiques t-SNE dépendent du nombre de points disponibles pour former les ensembles. La matrice de confusion et la courbe ROC-AUC sont plus représentatifs selon la quantité de données.

La question de la **quantité de données** est **essentielle** et met en relief un choix : la **qualité** ou la **quantité**. Il est donc nécessaire de réfléchir pour chaque cas de figure lors du déploiement d'un tel modèle. Privilégiez particulièrement les multiples méthodes de **validation croisées** sur des **base de données hétérogène à faible quantité** (Raschka 2018).




Fig. 31: Graphique comparant le score AUC moyen des modèles EfficientNetV2M avec le nombre de genres par base de données.

J-4 UNE SOLUTION PARCIMONIEUSE

J-4.1 APPLICATION REEL

Des nombreux paramètres et limitations exposés dans ce travail, les CNNs doivent être appliqués en connaissance de cause selon la situation. La capacité d'adaptabilité et la vitesse de la méthode en font une **alternative intéressante** dans un monde où les expertises sur certains clades très spécifiques se font rares.

Dans une perspective **communautaire**, cette méthode pourrait être parfaitement s'intégrer dans une **solution mobile** à l'instar de Pl@ntNet (Barthélémy *et al.* 2011). Les utilisateurs nourriraient le modèle en photos diverses de spécimens améliorant ces performances à chaque réentraînement. Pour limiter de mauvaise identification de la part de l'utilisateur, plusieurs solutions communautaires existent et pourrait être mises en place (Lefort *et al.* 2025). Ces propositions restent dépendantes de l'intérêt du public.

Cette proposition mobile est d'autant plus intéressante lors de prospection sur des zones mal connues ou peu cartographiées. Lorsque les spécimens paléontologiques sont le seul indice stratigraphique, il est important de pouvoir prendre des **décisions rapides** pour rentabiliser le **temps** et l'**investissement** alloués à la prospection. Un CNN à plusieurs prédictions (*e.g.* top 3, top 5) couplées à une charte biostratigraphique et des exemples photos serait intéressant pour des géologues d'exploration moins versés dans la paléontologie.

Une autre application serait d'utiliser les CNNs dans un but d'inventaire des **collections muséales** et de leur numérisation. De nombreux spécimens peuvent être **mal étiquetés** et les responsables des collections ne sont pas toujours spécialisés dans leur identification. Les images étant pris en condition d'éclairage contrôlé et des fonds généralement unis dans le cas des collections ou des publications, cette application serait la plus **compatible** avec les modèles présentés ici.

J-4.2 LIMITATION

Les modèles possèdent un **nombre de classes défini** et dans aucun cas ces derniers ne sont capables de spontanément en définir une autre. Pour cela, un **réentraînement constant** à intervalle régulier et des **ajouts de données** d'entraînement sont nécessaires pour élargir leur capacité de bonne prédiction. Pour toute autre interprétation liée au spécimen, un **avis d'un/une expert/e** dans le domaine est **nécessaire**.

Les CNN demande une quantité de **ressources importantes** et un certain temps d'entraînement. Sur un cas de figure à quelques dizaines de milliers de photos à haute résolution, les modèles les plus profonds demandent plus de 24 heures sur une carte graphique de dernière génération milieu de gammes (RTX 5070 12 Go). Les architectures InceptionResNetV2 et MobileNetv3 semble beaucoup moins intéressantes face à EfficientNetV2 par leur nombre d'époques plus important lors de l'entraînement. Dans un objectif plus généralisé avec des millions de photos de spécimens, le **temps d'entraînement augmenterait** de manière conséquente. De même, l'agrégation de la base de données peut être **chronophage et fastidieux**.

Les modèles très profonds ont une tendance à une **sur-confiance** lors de l'attribution des taux de prédiction. Si ces modèles sont utilisés dans une mesure de confiance, il est recommandé d'utiliser des **méthodes de calibration** telles que le *temperature scaling* (Guo *et al.* 2017) ou le *label smoothing* (Goodfellow *et al.* 2016).

J-4.3 PISTE D'AMELIORATION

Le facteur limitant principal est la quantité de données. Les spécimens sous-représentés sont en conséquence difficiles à intégrer à un CNN classique. Une alternative serait d'utiliser un **mixte** entre un **CNN classique** pour les genres possédant un nombre de photo conséquent et un **réseau siamois** sur les genres à faible quantité de données. Ce mixte de méthodes pourrait donner une couverture complète des genres/espèces photographiés moyennant une capacité d'identification disparate.

D'un point de vue taxonomique, sa **construction est hiérarchisée** contrairement à d'autre problématique d'identification. Il serait possible de faire des modèles de chaque rang pour avoir une **identification à multi-niveaux taxonomique**. Pour un spécimen donné, plusieurs modèles déterminent les taux de prédictions de toutes les classes à différent rangs taxonomiques. Avec de simples coefficients de pondération pour chaque modèle de rangs, il serait possible de calculer une **probabilité globale** avec le momentum des rangs supérieurs. Dans le cas d'identification indécise d'espèces, les identifications des rangs supérieurs pourraient orienter vers une meilleure identification.

K- CONCLUSION

Ce travail montre avec succès la capacité des modèles à identifier les céphalopodes du Trias et de la limite Permien/Trias au niveau générique et spécifique. Pour 95 genres et 34 espèces, les modèles montrent respectivement 68,61% et 77.27% de bonne prédictions basé sur des données de publications et de libre accès (Gbif). Les CNNs sont des outils rapides et versatiles dans leur utilisation à conditions de pouvoir les entraîner correctement en amont. Les données d'entraînement sont un facteur important par leur quantité et leur qualité de préservation et d'identification. De même, les architectures des CNNs jouent un rôle déterminant dans leur capacité à identifier les caractères déterminants. Cependant, leur mise en place demande des ressources en temps et en puissance de calcul. Le recoupage de diverses méthodes interprétatives sur la classification d'images permet d'apprécier les biais de manière multi-échelonnée avec confiance. Les CNNs sont des outils pour simplifier l'identifications mais des experts/es spécialisés/es restent plus que nécessaire pour toute autre interprétation poussée. Cette méthode éprouvée sur les microfossiles est de plus en plus appliquée sur des macrofossiles. Elle pourrait s'étendre sur des intervalles et un nombre de classes plus large pour une tentative d'identification globale des spécimens fossiles documentés.

L- DISPONIBILITE DES DONNEES

Tous les codes, les figures et la listes de publications utilisées lors de ce travail sont disponibles à l'adresse suivante : https://github.com/Pyraro/CNN-Triassic_cephalopods

Les bases de données sont disponibles à la demande auprès de l'Université de Bourgogne, à l'adresse électronique : titouan1305@gmail.com, ou à l'adresse suivante : <https://www.kaggle.com/datasets/pyraro/triassic-cephalopods>

M- REMERCIEMENT

Un grand merci à Arnaud BRAYARD, encadrant de stage, pour m'avoir fait confiance pour ce projet. Ces conseils ont été d'une grande aide tout au long de l'élaboration de ce mémoire. Merci également au camarade de ma promotion 2024-2025 pour cette joyeuse année passée avec eux. Merci finalement au laboratoire Biogéosciences de Dijon et à l'Université de Bourgogne pour la mise à disposition des locaux et de l'équipement.

N- BIBLIOGRAPHIE

Les références suivent le format de la revue *Bulletin of Geoscience* (<http://www.geology.cz/bulletin/instructions>).

- ACHANTA, R., SHAJI, A., SMITH, K., LUCCHI, A., FUA, P. & SÜSSTRUNK, S. 2012. SLIC Superpixels Compared to State-of-the-Art Superpixel Methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 34(11), 2274–2282. DOI 10.1109/TPAMI.2012.120
- ANSARI, Y., ISHAQ, M., YUSUF, M., QAISER, Y., HUSSAIN, R., RABBANI, H. & SEERS, T.D. 2024. Advancing Paleontology: A Survey on Deep Learning Methodologies in Fossil Image Analysis. DOI 10.21203/rs.3.rs-4663987/v1
- ARKELL, W.J., MOORE, R.C., MILLER, A.K., FURNISH, W.M., SCHINDEWOLF, O.H., KUMMEL, B. & WRIGHT, C.W. 1957. Part L, Mollusca 4, Complete Volume. *Treatise on Invertebrate Paleontology*. DOI 10.17161/dt.v0i0.5269
- ARTHABER, G. VON. 1911. *Die Trias von Albanien*. 109 pp. W. Braumüller, Wien.
- BARTHELEMY, D., BOUJEMAA, N., MATHIEU, D., MOLINO, J.-F., JOLY, A., GOËAU, H., BONNET, P., MOUYSET, E., BIRNBAUM, P., ROCHE, V., OUERTANI, W. & GRARD, P. 2011. The Pl@ntNet project: Plant Computational Identification and Collaborative Information System. In: *Biosystematics 2011 - Digital identification methods in the digital age - morphological and molecular, computer-aided and fully automated, research and citizen science*.
- BROMLEY, J., GUYON, I., LECUN, Y., SÄCKINGER, E. & SHAH, R. 1993. Signature Verification using a 'Siamese' Time Delay Neural Network. In: *Advances in Neural Information Processing Systems*. Morgan-Kaufmann.
- BRUGUIERE, J. 1789. JG 1789–1792. *Encyclopédique méthodique. Histoire naturelle des vers. Tome premier*, 1–344.
- CHOLLET, F. 2021. *Deep Learning with Python*. Second edition. 478 pp. Manning, Shelter Island, NY.
- CORTES, C., MOHRI, M. & ROSTAMIZADEH, A. 2009. L2 Regularization for Learning Kernels. In: *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*. AUAI Press, Arlington, Virginia, USA, UAI '09, 109–116.

- CURRIE, A. 2021. Stepping Forwards by Looking Back: Underdetermination, Epistemic Scarcity and Legacy Data. *Perspectives on Science* 29(1), 104–132. DOI 10.1162/posc_a_00362
- DELACOUR, H., SERVONNET, A., PERROT, A., VIGEZI, J.F. & RAMIREZ, J.M. 2005. La courbe ROC (receiver operating characteristic): principes et principales applications en biologie clinique. *Ann Biol Clin* 63.
- DENG, J., DONG, W., SOCHER, R., LI, L.-J., LI, K. & FEI-FEI, L. 2009. ImageNet: A Large-Scale Hierarchical Image Database. In: *2009 IEEE Conference on Computer Vision and Pattern Recognition – 2009 IEEE Conference on Computer Vision and Pattern Recognition*. 248–255. DOI 10.1109/CVPR.2009.5206848
- DOSOVITSKIY, A., BEYER, L., KOLESNIKOV, A., WEISSENBORN, D., ZHAI, X., UNTERTHINER, T., DEHGHANI, M., MINDERER, M., HEIGOLD, G., GELLY, S., USZKOREIT, J. & HOULSBY, N. 2020. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In: *International Conference on Learning Representations*.
- EASTMAN, C.R. & ZITTEL, K.A. VON. 1913. *Text-Book of Paleontology*. 2d ed., rev.enl. by the editor. Macmillan and Co., limited, London. DOI 10.5962/bhl.title.2100
- FABBRIZZI, S., PAPADOPOULOS, S., NTOUTSI, E. & KOMPATSIARIS, I. 2022. A survey on bias in visual datasets. *Computer Vision and Image Understanding* 223, 103552. DOI 10.1016/j.cviu.2022.103552
- FREBOLD, H. 1930. *Die Altersstellung des Fischhorizontes, des Grippianiveaus und des unteren Saurierhorizontes in Spitzbergen*. 60 pp. J. Dybwad, Oslo.
- GOODFELLOW, I., BENGIO, Y. & COURVILLE, A. 2016. *Deep Learning*. MIT Press.
- GRIESBACH. 1880. Paleontology notes on the Lower Trias of the himalayas. *Geological survey of india*.
- GUO, C., PLEISS, G., SUN, Y. & WEINBERGER, K.Q. 2017. On calibration of modern neural networks. In: *Proceedings of the 34th International Conference on Machine Learning - Volume 70*. JMLR.org, Sydney, NSW, Australia, ICML'17, 1321–1330.
- HAAN, G. DE. 1825. *Monographiae ammoniteorum et goniatiteorum specimen*. 188 pp. Apud H.W. Hazenberg.
- HE, K., ZHANG, X., REN, S. & SUN, J. 2016. Deep Residual Learning for Image Recognition. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) – 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 770–778. DOI 10.1109/CVPR.2016.90
- HE, K., GKIOXARI, G., DOLLÁR, P. & GIRSHICK, R. 2017. Mask R-CNN. In: *2017 IEEE International Conference on Computer Vision (ICCV) – 2017 IEEE International Conference on Computer Vision (ICCV)*. 2980–2988. DOI 10.1109/ICCV.2017.322
- HINTON, G., SRIVASTAVA, N. & SWERSKY, K. 2012. Neural Networks for Machine Learning. *University of Toronto: Department of Computer Science(6a)*, 1–31.

- HOCHREITER, S. 1998. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *Int. J. Uncertain. Fuzziness Knowl.-Based Syst.* 6(2), 107–116. DOI 10.1142/S0218488598000094
- HOWARD, A., SANDLER, M., CHEN, B., WANG, W., CHEN, L.-C., TAN, M., CHU, G., VASUDEVAN, V., ZHU, Y., PANG, R., ADAM, H. & LE, Q. 2019. Searching for MobileNetV3. In: *2019 IEEE/CVF International Conference on Computer Vision (ICCV) – 2019 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, Seoul, Korea (South), 1314–1324. DOI 10.1109/ICCV.2019.00140
- HOWARD, A.G., ZHU, M., CHEN, B., KALENICHENKO, D., WANG, W., WEYAND, T., ANDREETTO, M. & ADAM, H. 2017. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. *CoRR abs/1704.04861*.
- HSIANG, A.Y., BROMBACHER, A., RILLO, M.C., MLENECK-VAUTRAVERS, M.J., CONN, S., LORDSMITH, S., JENTZEN, A., HENEHAN, M.J., METCALFE, B., FENTON, I.S., WADE, B.S., FOX, L., MEILLAND, J., DAVIS, C.V., BARANOWSKI, U., GROENEVELD, J., EDGAR, K.M., MOVELLAN, A., AZE, T., DOWSETT, H.J., MILLER, C.G., RIOS, N. & HULL, P.M. 2019. Endless Forams: >34,000 Modern Planktonic Foraminiferal Images for Taxonomic Training and Automated Species Recognition Using Convolutional Neural Networks. *Paleoceanography and Paleoclimatology* 34(7), 1157–1177. DOI 10.1029/2019PA003612
- HUANG, G., LIU, Z., VAN DER MAATEN, L. & WEINBERGER, K.Q. 2017. Densely Connected Convolutional Networks. In: *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) – 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, Honolulu, HI, 2261–2269. DOI 10.1109/CVPR.2017.243
- HYATT, A. 1879. Genesis of the Arietitidae: Smiths. *Contrib. Knowl* 26, 673.
- HYATT, A. 1884. The Evolution of the Cephalopoda.—II. *Science ns-3(53)*, 145–149. DOI 10.1126/science.ns-3.53.145
- HYATT, A. & SMITH, J.P. 1905. *The Triassic Cephalopod Genera of America*. 394 pp. Govt. Print. Off., Washington, Geological Survey (U.S.). Professional paper ;no.40.
- HYATT, A., ZITTEL, K.A. VON, EASTMAN, C.R., SCHLOSSER, M. & WOODWARD, A.S. 1900. *Text-Book of Palaeontology*. English ed. rev. and enl. by the author and editor in collaboration with specialists. 726 pp. Macmillan, London. DOI 10.5962/bhl.title.61554
- IOFFE, S. & SZEGEDY, C. 2015. Batch normalization: accelerating deep network training by reducing internal covariate shift. In: *Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37*. JMLR.org, Lille, France, ICML'15, 448–456.
- KINGMA, D.P. & BA, J. 2015. Adam: A Method for Stochastic Optimization. In: Bengio, Y. & LeCun, Y. (eds) *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*.
- KITTS, D.B. 1974. Paleontology and Evolutionary Theory. *Evolution* 28(3), 458–472. DOI 10.2307/2407167

- KRIZHEVSKY, A., SUTSKEVER, I. & HINTON, G.E. 2012. ImageNet Classification with Deep Convolutional Neural Networks. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc.
- KROGH, A. & HERTZ, J. 1991. A Simple Weight Decay Can Improve Generalization. In: *Advances in Neural Information Processing Systems*. Morgan-Kaufmann.
- LANDMAN, N.H., TANABE, K. & DAVIS, R.A. 1996. *Ammonoid Paleobiology*. 857 pp. Springer-Verlag New York Inc., Boston, MA s.l.
- LAUBE, G.C. 1869. *Separatabdrücke aus den Sitzungsberichten der Keis: Akademie der Wissenschaften in Wien*. 32 pp.
- LEFORT, T., AFFOUARD, A., CHARLIER, B., LOMBARDO, J.-C., CHOUET, M., GOËAU, H., SALMON, J., BONNET, P. & JOLY, A. 2025. Cooperative learning of Pl@ntNet's Artificial Intelligence algorithm: How does it work and how can we improve it? *Methods in Ecology and Evolution* n/a(n/a). DOI 10.1111/2041-210X.14486
- LINNAEUS, C. VON. 1758. *Systema Naturae, per Regna Tria Naturae: Secundum Classes, Ordines, Genera, Species Cum Characteribus, Differentiis, Synonymis, Locis*. Ed. 13. Typis Ioannis Thomae, Vindobonae, Vienna. DOI 10.5962/bhl.title.559
- LINNAINMAA, S. 1976. Taylor expansion of the accumulated rounding error. *BIT* 16(2), 146–160. DOI 10.1007/BF01931367
- LIU, X., JIANG, S., WU, R., SHU, W., HOU, J., SUN, Y., SUN, J., CHU, D., WU, Y. & SONG, H. 2023. Automatic taxonomic identification based on the Fossil Image Dataset (>415,000 images) and deep convolutional neural networks. *Paleobiology* 49(1), 1–22. DOI 10.1017/pab.2022.14
- MAATEN, L. VAN DER & HINTON, G. 2008. Visualizing Data using t-SNE. *Journal of Machine Learning Research* 9(86), 2579–2605.
- MATHEWS, A.A.L. & KAPPA EPSILON PI. 1929. *The Lower Triassic Cephalopod Fauna of the Fort Douglas Area, Utah*. v, 46 pages pp. University of Chicago Press, Chicago, Ill., Walker Museum memoirs ;v. 1, no. 1.
- MOJSISOVICS, E. 1893. Das Gebirge um Hallstatt, Theil I, Die Cephalopoden der Hallstätter Kalke. *Abhandlungen der Kaiserlich-Königlichen Geologischen Reichsanstalt* 6, 1.
- MOJSISOVICS, E. VON. 1882. *Die Cephalopoden der mediterranen Triasprovinz*. 726 pp. Hölder.
- MONNET, C. & BUCHER, H. 2005. New Middle and Late Anisian (Middle Triassic) ammonoid faunas from northwestern Nevada (USA): taxonomy and biochronology. In: *New Middle and Late Anisian (Middle Triassic) Ammonoid Faunas from Northwestern Nevada (USA): Taxonomy and Biochronology*. Taylor & Francis, Fossils and Strata, 1–121. DOI 10.18261/9781405163651-2005-01
- NOETLING, F. 1904. Ueber Medlicottia Waag. und Episageceras ng aus den permischen und triadischen Schichten Indies. *Neues Jahrbuch für Mineralogie, Geologie und Palaontologie* 19, 334–376.

- PAN, S.J. & YANG, Q. 2010. A Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering* 22(10), 1345–1359. DOI 10.1109/TKDE.2009.191
- PEARSON, K. 1901. LIII. *On lines and planes of closest fit to systems of points in space. The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 2(11), 559–572. DOI 10.1080/14786440109462720
- PEREZ, E. & PIGNAL, M. 2013. Numériser et promouvoir les collections d’histoire naturelle. *Bulletin des bibliothèques de France (BBF)*(n° 5), 27–30.
- RACHOOTIN, S. 1981. Epigenetics, paleontology, and evolution. *Evolution today (GGE Scudder; JL Raveau)*.
- RADIUK, P. 2017. Impact of Training Set Batch Size on the Performance of Convolutional Neural Networks for Diverse Datasets. *Information Technology and Management Science*. DOI 10.1515/ITMS-2017-0003
- RASCHKA, S. 2018. Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning. *ArXiv*.
- RIBEIRO, M.T., SINGH, S. & GUESTRIN, C. 2016. ‘Why Should I Trust You?’: Explaining the Predictions of Any Classifier. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Association for Computing Machinery, New York, NY, USA, KDD ’16, 1135–1144. DOI 10.1145/2939672.2939778
- RICHTER, M.L., BYTTNER, W., KRUMNACK, U., WIEDENROTH, A., SCHALLNER, L. & SHENK, J. 2021. (Input) Size Matters for CNN Classifiers. In: Farkaš, I., Masulli, P., Otte, S. & Wermter, S. (eds) *Artificial Neural Networks and Machine Learning – ICANN 2021*. Springer International Publishing, Cham, 133–144.
- ROBBINS, H. & MONRO, S. 1951. A Stochastic Approximation Method. *The Annals of Mathematical Statistics* 22(3), 400–407. DOI 10.1214/aoms/1177729586
- ROCHA-ORTEGA, M., RODRIGUEZ, P. & CÓRDOBA-AGUILAR, A. 2021. Geographical, temporal and taxonomic biases in insect GBIF data on biodiversity and extinction. *Ecological Entomology* 46(4), 718–728. DOI <https://doi.org/10.1111/een.13027>
- SCHOPF, J.M. 1975. Modes of fossil preservation. *Review of Palaeobotany and Palynology* 20(1–2), 27–53. DOI 10.1016/0034-6667(75)90005-6
- SELVARAJU, R.R., COGSWELL, M., DAS, A., VEDANTAM, R., PARIKH, D. & BATRA, D. 2017. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. In: *2017 IEEE International Conference on Computer Vision (ICCV) – 2017 IEEE International Conference on Computer Vision (ICCV)*. 618–626. DOI 10.1109/ICCV.2017.74
- SILBERLING, N.J. 1959. *Pre-Tertiary Stratigraphy and Upper Triassic Paleontology of the Union District Shoshone Mountains Nevada*. Professional Paper.
- SMITH, J.P. 1927. Upper Triassic marine invertebrate faunas of North America. *Professional Paper*. DOI 10.3133/pp141

- SPATH, L. & OTHERS. 1929. Corrections of cephalopod nomenclature. *The Naturalist* 871, 269–271.
- SPATH, L.F. 1930. *The Eotriassic Invertebrate Fauna of East Greenland*. 576 pp. C. A. Reitzel.
- SPATH, L.F. 1934. *The Ammonoidea of the Trias*. Catalogue of the fossil cephalopoda in the british museum.
- SRIVASTAVA, N., HINTON, G., KRIZHEVSKY, A., SUTSKEVER, I. & SALAKHUTDINOV, R. 2014. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research* 15(56), 1929–1958.
- SUESS, E. 1865. Über Ammoniten. *Sitzungsberichte der Kaiserlichen Akademie der Wissenschaften in Wien, Mathematisch-naturwissenschaftliche Klasse* 52, 71–89.
- SUN, J., LIU, X., HUANG, Y., WANG, F., SUN, Y., CHEN, J., CHU, D. & SONG, H. 2023. Automatic identification and morphological comparison of bivalve and brachiopod fossils based on deep learning. *PeerJ* 11, e16200. DOI 10.7717/peerj.16200
- SZEGEDY, C., IOFFE, S., VANHOUCKE, V. & ALEMI, A.A. 2017. Inception-v4, inception-ResNet and the impact of residual connections on learning. In: *Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence*. AAAI Press, San Francisco, California, USA, AAAI'17, 4278–4284.
- TAN, M. & LE, Q.V. 2019. *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. 6105–6114 pp. PMLR, Long Beach, Proceedings of the 36th International Conference on Machine Learning.
- TONGTHERM, K., SHIGETA, Y., SARSDUD, A., SASHIDA, K. & AGEMATSU, S. 2020. Age of the Early Triassic Ichthyopterygian Thaisaurus Inferred from Ammonoid Biostratigraphy. *Paleontological Research* 24(4). DOI 10.2517/2019PR022
- TROUDET, J., GRANDCOLAS, P., BLIN, A., VIGNES-LEBBE, R. & LEGENDRE, F. 2017. Taxonomic bias in biodiversity data and societal preferences. *Scientific Reports* 7(1), 9132. DOI 10.1038/s41598-017-09084-6
- TURING, A.M. 1950. COMPUTING MACHINERY AND INTELLIGENCE. *Mind* LIX(236), 433–460. DOI 10.1093/mind/LIX.236.433
- VASWANI, A., SHAZEER, N., PARMAR, N., USZKOREIT, J., JONES, L., GOMEZ, A.N., KAISER, Ł. UKASZ & POLOSUKHIN, I. 2017. Attention is All you Need. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc.
- VON MOJSISOVICS, E. 1873. *Die Cephalopoden Der Hallstätter Kalke*. KK Geologische Reichsanstalt, Wien.
- WAAGEN, W.H. 1895. *Salt-Range Fossils: Fossils from the Ceratite Formation. Pt. 1*. 1895. book pp. Geological Survey Office, Wien.
- WELTER, O.A. 1914. *Die obertriadischen ammoniten und nautiliden von Timor*. 1–362 pp. Buchdruckerei von Gustav Schade (Otto Francke), Berlin, Germany.

- WELTER, O.A. 1922. *XIX. DIE AMMONITEN DER UNTEREN TRIAS VON TIMOR*. Schweizebart (Erwin Nagele), Stuttgart.
- WHITE, C.A. 1879. On the Permian Formation of Texas. *The American Naturalist* 23(266), 109–128. DOI 10.1086/274870
- WIECZOREK, J., BLOOM, D., GURALNICK, R., BLUM, S., DÖRING, M., GIOVANNI, R., ROBERTSON, T. & VIEGLAIS, D. 2012. Darwin Core: An Evolving Community-Developed Biodiversity Data Standard. *PLOS ONE* 7(1), e29715. DOI 10.1371/journal.pone.0029715
- ZHANG, Y., TINO, P., LEONARDIS, A. & TANG, K. 2021. A Survey on Neural Network Interpretability. *IEEE Transactions on Emerging Topics in Computational Intelligence* 5(5), 726–742. DOI 10.1109/TETCI.2021.3100641